

数据挖掘技术在高校图书馆个性化服务中的应用研究



重庆大学硕士学位论文
(学术学位)

学生姓名：王 哲

指导教师：彭晓东 教 授

专 业：图书馆、情报与档案管理

学科门类：管理学

重庆大学经济与工商管理学院

二〇一二年五月

Research on the Application of Data Mining in the Personalized Service of College Libraries



A Thesis Submitted to Chongqing University
in Partial Fulfillment of the Requirement for
the Master's Degree of Management

By
Wang Zhe

Supervised by Prof. Peng Xiaodong
Specialty: Library and Information Science

College of Economics and Business Administration Chongqing
University, Chongqing, China

May.2012

摘 要

随着信息技术的高速发展, Lib2.0 技术的出现, 信息化的盛行, 高校图书馆在这一进程中积累了大量数据, 使得读者不能快速便捷的获取自己所需的信息资源, 促使高校图书馆必需扩大服务空间, 因此个性化服务成为了图书馆服务模式的主流, 变传统图书馆的被动服务为主动服务, 向用户主动推荐图书。

本文首先对国内外高校图书馆个性化服务系统的应用现状进行了对比分析, 并对数据挖掘的概念、任务、方法及过程进行了系统的阐述, 同时介绍了图书分类及数字图书馆个性化信息服务方式等相关知识。然后通过分析发现, 当前高校图书馆采用的图书馆系统都不具备数据挖掘分析功能, 基于此, 本文拟在图书馆集成系统的基础上设计一个配套的基于数据挖掘技术的个性化推荐系统模型, 从理论角度上对模块的具体组成、功能描述及其工作流程进行了详细说明。

在具体实践研究中, 以重庆大学图书馆的历史借阅记录为具体挖掘对象, 应用数据挖掘技术, 研究了高校图书馆个性化系统服务层中的数据处理模块(含数据采集)及数据挖掘模块的具体实现, 进一步实现用户信息行为及知识库的建立, 并对挖掘结果提出一些具体的推荐建议。主要从两个方面实施挖掘分析:

一方面, 采用聚类分析, 对图书馆的读者进行有效的分类, 使得每个群中具有相似的借阅模式, 据此对用户进行建模。

另一方面采用关联规则挖掘分别以全部读者和已聚类的读者为挖掘对象进行挖掘分析, 找出具有强关联性的图书, 并提取规则模式, 建立知识库(规则库)最终根据得出的规则模式与读者进行匹配向读者进行个性化图书推荐。

最后, 对本文研究进行了全面总结, 展望了未来进一步研究的方向。

关键词: 数字图书馆, 个性化服务, 数据挖掘, 关联规则

ABSTRACT

With the rapid development of the information technology, the appearance and popular of lib2.0 and informationization.College library has accumulated large amounts of data in the process, So that the reader can't fast and convenient get that they need information resources. The reasons for college library necessary expand service spaces. So the individualized service became the mainstream mode of the library service, This model transitions the passive service of the traditional library into active service, recommending books to users depending on their interest profile actively.

First this paper comparative analysis both of present situation of the application of personalized service system of domestic and international university library. Systemic explanation about the concept of data mining、task、method and process, in the meanwhile, introduces about related knowledge of the book classification and digital library individualized information service mode. This paper has a discovery with analysis of Library integrated system, which used by majority of college library. The discovery is that these systems don't have data mining feature. In this paper, we will design a supporting system of based on data mining technology personalized recommendation based on the library-integrated system. We make a detailed illustration to the specific module composition, functional description and working flow from angle of fundamental research.

In the study of concrete realization, this paper using data mining technology, making the log of borrowing and reading of Chong Qing university library as the research object, studying concrete realization of data processing (Including data acquisition) and mining analysis in the personalized recommendation system of college library, Further realize the information behavior and the establishment of the knowledge base and put forward some concrete results mining recommendations. We mainly analysis for mining from two aspects.

On the one hand, make effective group classification of readers of library using clustering analysis and each group that has similar borrowing mode. According to the results of the clustering build user model.

On the other hand, With all the readers and are already clustering reader for mining object use of association rules mining for mining analysis. Find out the strong relevance books and extracting rules model, establish knowledge base. Finally, volunteer actively

recommend books according to the rules that eventually mode matching with readers

Finally, This paper make a comprehensive summary for this research, and look to the future direction of further study.

Keywords: digital library, personalized service, data mining, association rule

目 录

中文摘要.....	I
英文摘要.....	II
1 绪 论.....	1
1.1 选题背景.....	1
1.2 研究目的及意义.....	2
1.2.1 研究目的.....	2
1.2.2 研究意义.....	2
1.3 国内外研究现状.....	3
1.3.1 国外研究现状.....	3
1.3.2 国内研究现状.....	4
1.3.3 国内外研究现状的比较.....	4
1.4 论文的组织结构.....	6
2 相关理论与技术基础.....	7
2.1 数据挖掘概述.....	7
2.2 数据挖掘的任务与方法.....	8
2.2.1 数据挖掘的任务.....	8
2.2.2 数据挖掘方法.....	9
2.3 数据挖掘的过程.....	10
2.3.1 数据挖掘的环境.....	10
2.3.2 数据挖掘的过程步骤.....	11
2.4 数字图书馆个性化信息服务.....	12
2.4.1 数字图书馆个性化信息服务概述.....	12
2.4.2 数字图书馆个性化信息服务的方式.....	13
2.5 国内图书馆自动化系统及分类法简介.....	15
3 数字图书馆个性化系统模型设计.....	18
3.1 数字图书馆个性化系统设计背景.....	18
3.2 数字图书馆个性化系统设计目的和思路.....	18
3.2.1 设计目的.....	18
3.2.2 设计的思路.....	19
3.3 个性化系统结构模型设计.....	20
3.3.1 整体结构模型.....	20

3.3.2 功能描述	22
3.3.3 工作流程	23
3.3.4 个性化推荐模块的组成	23
4 个性化服务数据挖掘实施	25
4.1 图书馆数据挖掘数据源的选取	25
4.2 借阅数据的处理	26
4.2.1 数据清洗	28
4.2.2 数据转换	31
4.2.3 数据集成	33
4.3 算法的选择	36
4.3.1 关联算法的比较	36
4.3.2 聚类算法比较	36
4.4 基于聚类对读者细分	38
4.4.1 借阅情况聚类挖掘	38
4.4.2 读者偏好、类型上的聚类挖掘	40
4.5 关联规则挖掘	44
4.5.1 基于图书的关联分析	44
4.5.2 全部读者所借图书关联挖掘	44
4.5.3 已聚类群中的关联挖掘	46
4.5.4 关联规则的推荐	48
5 结论与展望	49
5.1 结论	49
5.2 展望	49
致 谢	51
参考文献	52
附 录	55
作者在攻读学位期间发表的论文目录	55

1 绪 论

1.1 选题背景

随着人类生活水平的逐步提高，服务行业的服务范围、服务层面有了新的扩展，服务理念更加深入人心，服务逐渐成为人类永恒的话题。图书馆——最早服务于人类的一个机构，也越来越重视到其服务这一宗旨的重要性。随着信息技术的发展，需要存储和传播的信息量越来越大，信息的种类和形式越来越丰富，传统图书馆的机制显然不能满足这些需要。因此，数字图书馆应运而生。数字图书馆是一个电子化信息的仓库，能够存储大量各种形式的信息，用户可以通过网络方便地访问它，以获得这些信息，并且其信息存储和用户访问不受地域限制。虽然信息的种类和形式越来越丰富，但是质量参差不齐，读者要花费大量的时间去寻求自己所要的信息，到最后可能是一些价值不大或者纯粹的垃圾信息。要如何从浩瀚的各种资源中找到自己所需要的信息资源这不仅是广大读者的一个难题，对高校图书馆而言也将是一个挑战。因为对于读者而言，都愿意倾注少量的时间与物力来满足自己的需求，这样一来，谁提供的服务快捷、信息准确，能满足个性化需求，谁将会得到读者的青睐。美国图书馆与信息技术联合会（LITA）10位著名的数字图书馆专家早在1999年的讨论会上，把个性化定制服务列为数字图书馆发展的七大趋势之首。可见，个性化信息服务将成为数字图书馆的发展方向。^[1]经过对近几年的文献检索得知，在国外，如美国、日本、英国、法国等国家十分注视数字图书馆的建设，均投入了巨额的资金对该项目进行研究，其中在图书馆的个性化服务方面，以上四个国家均处于领先地位。但在国内而言，开展个性化服务的成功实例还很少。其中以 Mylibrary 模式最为典型，它的服务模式强调以读者个性化需求为中心。但点击进入那些图书馆主页上设有“Mylibrary”栏目，发现里面并没有什么实质性的内容。

因此，为了满足读者的个性化需求、创新图书馆服务模式、顺应时代的潮流，图书馆的服务功能应从被动型向主动型转变。我们需要利用新的科技成果服务于图书馆。无独有偶，另一项技术，即数据挖掘技术的出现与发展为图书馆服务功能开辟了新篇章，使图书馆服务功能从被动型到主动型的转变成为可能，更为图书馆开展个性化服务创造了有利条件。

在1989年第11届国际联合人工智能学术会议上首次提出数据库中的知识发现（Knowledge Discovery in Database，简称KDD）^[2]之后，数据挖掘居于1995年开始了它的第一届知识发现与数据挖掘国际会议。至此数据挖掘越来越受专家学者的关注，现已成为计算机领域研究的一大热点。其应用领域也越来越广，数

据挖掘技术可以用来支持广泛的商务智能应用，如顾客分析、定向营销、工作流程管理、商店分布和欺诈检测等。同时医学、科学与工程技术界的研究者正在快速积累大量数据，利用数据挖掘找出的潜在的有价值的新发现至关重要。同样数据挖掘技术也能够有效的解决图书馆所面临的问题。数据挖掘作为技术支撑，图书馆的业务数据作为信息基础，这样一来，有了技术，有了数据，对读者的个性化服务将成为可能。

1.2 研究目的及意义

1.2.1 研究目的

随着信息技术的不断发展，各行各业正在经历一种信息化浪潮，图书馆作为一个信息资源中心，也顺应着信息化潮流，向前发展。在信息化的进程中，图书馆积累了大量的数字信息资源。在如此多的信息资源中，读者如何能够方便快捷的找到自身所需的信息已经是当前图书馆所面临的一大难题，在这一关键时刻，成熟的信息技术，数据挖掘为我们指明了一个很好的解决问题的方向，该技术中强大的聚类分析与关联规则分析方法能够变图书馆的被动服务为主动服务。笔者希望通过这次研究，让数据挖掘、个性化推荐理念深入人心，在现有图书馆系统下，建立个性化服务系统整体结构模型，利用数据挖掘技术通过个性化服务系统实现个性化推荐，满足读者需求。最后以重庆大学图书馆历史借阅记录为具体挖掘对象，研究了个性化服务系统的具体实现。

1.2.2 研究意义

①理论意义

由于用户的信息需求与形式越来越多样化，对数据资源的类型也越来越广泛化，因此个性化的信息服务成为了新的发展趋势。^[3]从国际和理论上来看，图书馆的发展经历了三个阶段：印刷纸张图书馆，自动化集成图书馆以及数字图书馆。^[4]在信息时代，数字图书馆作为一个信息仓库，里面存储了大量的信息，纵然有着海量的资源，但不能根据读者的偏好为其提供有针对性的信息资源服务，这就使得图书馆里的资源不能让用户得到有效的利用。纵观现在数字图书馆的功能均是一键式检索服务，读者需要什么样的书籍要进入该馆主页进行检索，然后只能从其检索中的结果中找。检索中的结果不仅多、杂、乱，而且大部份是与我们所需求的无关的信息。尽管我国高校图书馆正在致力于开展个性化信息服务，如定题服务、对口服务等。但是由于技术的不足，并未实现真正意义上的个性化服务。用户对他们的需求有了更高的要求，希望图书馆能够根据他们的兴趣爱好进行个性化的推荐，并能够识别他们兴趣的转移情况而进行最新的兴趣推荐。因此，根据用户的偏好提供个性化的信息服务将是未来数字图书馆发展研究的趋势。

数字图书馆个性化信息服务功能的应用可以使图书馆变被动为主动服务。以前要借一本书或是找一些文献资料, 我们需要提供书名或是检索号从数字图书馆中去查找。如果有了个性化信息服务, 图书馆可以利用我们的访问足迹通过数据挖掘技术分析出读者的兴趣爱好, 最终根据读者的兴趣主题向读者主动推荐图书或其他信息资源。

②实践意义

图书馆作为信息存储与服务的中心, 随着时间的推移, 积累了丰富的信息资源, 而图书管理系统中传统的查询统计功能无法从大量数据中发现先前未知的有用知识模式, 也没有预测未来观测结果的能力。从而无法为读者提供更便利高效的服务。我们应该考虑采用数据挖掘技术从图书馆这个大的数据仓库中自动地发现有用的信息, 来为读者提供个性化服务, 这对图书馆信息资源的有效利用有着重要的实践意义。表现在以下几个方面:

1) 优化馆藏: 通过对图书馆借阅情况结果的分析与高校学科设置情况进行对比分析, 可以为图书馆书籍的采购、上架、排架及剔除的合理性提供依据。

2) 读者服务: 图书馆借阅纪录中保存着大量潜在的有价值的信息, 我们需要用数据挖掘技术对这些信息进行加工处理, 找出读者的借阅行为模式, 如一个读者在某次借阅中同时借阅书本 A 和 B, 且在纪录中存在这样的现象, 即这两本书被多个人同时借出, 那么我们可以推出借阅 A 书的人可能也会对 B 书感兴趣, 基于此我们可以将书本 B 推荐给借阅书本 A 的人。这就是一个关联现象, 即在书本 A 与 B 之间存在着较强的关联——借阅书本 A 的人会对书本 B 也感兴趣。

3) 提高图书馆在高校中的地位: 在过去图书馆只是作为一个存储信息资源的地方, 一直都会被读者忽视, 只有在人们有需求时才会拜访图书馆。如今开展个性化推送服务, 可以使读者不只是在有需求时才会记起, 图书馆可以定期或随时向读者推荐他们感兴趣的书籍或其他信息, 这样使得图书馆将自身营销出去。让读者感受到图书馆随时都存在, 这样就能在不知不觉中提高了图书馆的地位。

4) 扩大图书馆服务层面: 开展个性化服务转变图书馆被动为主动服务, 使图书馆的服务从借、阅文献资源上升到更高层次的服务。

1.3 国内外研究现状

1.3.1 国外研究现状

1990 年初美国政府开始建设数字图书馆, 紧跟其后其他一些发达国家如, 法国、英国、意大利、日本、德国等国家的图书馆都竞相开发了数字图书馆个性化信息服务系统。从化市图书馆徐杰飞^[5]以文献检索的方式对发表在 ISI WEB of Knowledge 数据库中的有关个性化服务的文章进行统计分析, 在 2004-2009 年之间,

总共有 1079 篇相关论文,在个性化服务研究文献中,计算机科学最多,其次为机械学和电讯学,而图书馆个性化研究仅排在第 8 位。考虑其与其他学科的交叉性可以发现国外学者对图书馆个性化服务研究还是非常积极的。自 1998 年 Eric Lease Morgan 领导的团队开发了 MyLibrary@NCState 后,MyLibrary 系统已经成为图书馆个性化服务中的一种典型模式^[6]。如北卡罗莱纳州立大学 My Library@LANL 系统^[7],美国华盛顿大学图书馆的 MyGateway 系统^[8],加利福尼亚大学洛杉矶分校的 MyUCLA 系统^[9],罗彻斯特大学图书馆的 CoURse Resources 系统^[10],康纳尔大学图书馆的 My Library@Cornell 系统都比较成熟^[11]。英国南安普敦大学使用本体的方法解决了用户信息化的描述问题,为获取用户个性化信息提供了一个可行的方法。以上个性化信息服务系统中以康纳尔大学的 MyLibrary@Cornell 系统最具特色。它由三个部分组成: MyLinks, MyUpdates 和 MyContents。纵观各大学建设的个性化服务系统,虽然在算法语言上较有不同外,其服务的方式主要有两种:①个性化信息分类定制:分类定制是指用户根据自己的目的地和需求自己设定信息的资源类型、表现形式,选取特定的系统服务功能。②信息推送服务:运用推送技术将信息推送给用户以满足其需求,而不需要用户自己进行订阅的一种服务方式。这两种服务方式也即是对个性化服务中的个性化与主动性两个方面的具体应用。

1.3.2 国内研究现状

国内研究相对于国外研究起步比较晚,直到 20 世纪末期,中国才开始对数字图书馆的个性化服务展开研究,目前的研究还处于初步探索阶段。在文献研究方面,北华大学图书馆的徐艳对 2000-2010 年间发表在 CNKI 上的有关图书馆个性化服务研究的文献进行统计分析^[12],结果发现总共有 508 篇相关论文,且研究内容主要包括在以下几个方面:(1)个性化服务的概述及其现状分析;(2)服务方式和环境的个性化;(3)服务内容的个性化;(4)个性化服务中技术的应用。在系统建设方面,国内的 MyLibrary 系统起步也比较晚,成型的系统较少,但也取得了一些成果,其中清华大学的网络信息实验室,已将个性化信息检索系统作为其研究课题之一。^[13]几个比较有代表性的系统有,中国科学院国家科学数字图书馆基于北卡州立大学的 Mylibrary@NCState 系统开发的“我的数字图书馆——基于个性化集成定制的门户网站”^[14]、浙江大学的 MyLibrary@ZJU 系统^[15]、华中科技大学的 MyLibrary@HUST 系统^[16]、中国人民大学的数字图书馆的 Kingbase DL 个性化推荐系统^[17]、深圳图书馆开发的 ILAS“图书馆自动化集成系统”。其中以浙江大学图书馆开发的 MyLibrary@ZJU 系统最具代表性。其系统设计采用当前比较流行的 Browser/server 模式,数据库服务器、web 服务器和客户浏览器是其主要组成部分。

1.3.3 国内外研究现状的比较

目前在全世界范围内各国家、高校图书馆都在开展个性化系统研究,其中以

MyLibrary 系统的应用最为广泛，纵观各高校图书馆 MyLibrary 系统的服务功能无不包括以下几个方面：①向用户提供本馆（包括本地和远程的）电子资源的链接列表；②提供统一的检索平台；③根据用户需求进行主动推送；④根据用户的研究方向或兴趣进行协同推送。这些功能设计的理念都没有离开个性化所具有的特性——个性化和主动性。

以下我们通过表 1 对国内外几个具有代表性的 MyLibrary 个性化系统的服务功能进行比较分析。

表 1.1 国内外大学 MyLibrary 系统主要服务功能对比分析

Table1.1 Domestic and international university MyLibrary system mainly service function of comparative analysis

服务功能	高校图书馆	北卡罗莱纳 州立大学	康纳尔 大学	多伦多 大学	中科院 图书馆	浙江 大学	华中科 技大学
定制图书馆资源及其他 WEB 资源		√	√	√	√	√	√
个人图书馆管理		√	√	√	√	√	√
最新资源通告消息管理		√	√	√	√	√	√
与图书馆通话系统 OPAC 的 接入		√	√	√	√	√	√
个人链接收藏		√	√	√	√	√	√
页面资源布局、色彩字体的定制		√	√	√	√	√	√
查阅图书馆目录及借阅记录		√	√	√	√	√	√
提供馆际互借和原文传递服务		√	√				√
个性化页面及资源显示		√			√	√	√
提供书签功能（bookmarklets）				√		√	
与搜索引擎连接		√					
共享图书馆				√			
图书馆选择资源的自动 更新下载				√			
本地快速检索 （只查某学科资源）		√					
网站资源可添加到我的图书馆				√			
用户密码加密保存						√	
更多图书馆链接						√	

从表 1.1 中我们可以看出,各高校图书馆 MyLibrary 系统中都有前 7 项服务功能。这也刚好说明了各图书馆都在致力于服务功能的个性化与主动性,这些也都是 MyLibrary 系统的基本功能。如个人图书馆管理、个人链接收藏等均体现了个性化这一理念,而最新资源通告消息管理、与图书馆通话系统 OPAC 的接入则体现了主动性这一理念。同时各图书馆之间也有其不同之处,各有自己的特色功能,如浙江大学的用户密码加密保存为用户提供安全性服务,北卡罗莱纳州立大学提供本地快速检索,读者可以从弹出的菜单中选择定制常用的书籍和数据库,进行快速简捷的检索,当检索完成时系统将记录下这些内容以便以后提供参考。多伦多大学图书馆提供的图书馆选择资源的自动更新下载功能保证了信息资源的时效性与新颖性。

从各高校图书馆提供的个性化服务功能的完备性和多样性来看,国外大学图书馆提供的服务功能较多,除了在基本功能上较完备外,其特色功能较多。国内只有浙江大学图书馆自身具有两个特色功能外,其余两所高校的特色服务均与国外高校图书馆提供的服务雷同。

从整体上来看,各高校图书馆个性化服务系统提供的功能普遍比较单一,服务内容与形式不丰富,相比于服务的个性化而言,其服务功能的主动性程度不高。在信息推送方面做的不够好,也没有开展智能代理式的主动搜索功能。

1.4 论文的组织结构

本文主要研究数字图书馆个性化服务系统的模型建立及数据挖掘技术在数字图书馆个性化服务系统中的应用。

本文主要分为五个部分:

第一章中,主要介绍了论文的研究背景,目的意义及国内外研究现状及论文组织结构。

第二章中,介绍了数据挖掘相关知识,并对数字图书馆中的个性化服务进行了讨论

第三章中,分析图书馆系统的服务功能,了解系统的组成,发现图书馆中个性化服务中的缺点,基于此,设计一个基于数据挖掘技术的个性化服务模型,通过对读者借阅信息的收集、加工和处理,为进一步实现个性化服务提供数据基础。

第四章中,利用聚类技术,实现 K-means 算法在用户聚类中的具体应用。建立读者借阅模型,最后根据聚类结果采用关联规则技术找出借阅规则模式,形成规则库(知识库),实现个性化推荐。

第五章中,对全文进行了总结,并对未来进行了展望。

2 相关理论与技术基础

2.1 数据挖掘概述

数据收集和数据存储技术的快速进步使得各组织机构可以积累海量数据。然而，提取有用的信息已经成为巨大的挑战。通常，由于数据数量太大，无法使用传统的数据分析工具和技术处理它们。有时，即使数据集相对较小，由于数据本身的非传统特点，也不能使用传统的方法处理。在另外一些情况下，需要回答的问题不能使用已有的数据分析技术来解决。这样，就需要开发新的方法。

为迎接以上的这些挑战，来自不同学科的研究者汇集到一起，开始着手开发可以处理不同数据类型的更有效、可伸缩的工具。在 1989 年举行的第十一届国际联合人工智能学术会议上首次提出从数据库中发现知识（KDD）这一词，到目前为止，由美国人工智能协会主办的 KDD 国际研讨会已经召开了 8 次，规模由原来的专题讨论会发展到国际学术大会（见表 2.1）。

表 2.1 历届 KDD 国际学术会议一览表

Table2.1 The list of the international academic conferences KDD

时间	会议名称	会议地点	收录论文比例	参会人数
1989.6	Workshop on KDD	Detroit, Michigan, USA	2:1	30
1991.7	Workshop on KDD	Anaheim, California	3.5:1	46
1993.7	Workshop on KDD	Washington, USA	3:1	40
1995	KDD95	Montreal, Canada	4.5:1	340
1996.8	KDD96	Portland, Oregon, USA	5:1	450
1997.2	PAKDD97	Singapore	3.5:1	97
1997.8	KDD97	California, USA	6:1	600
1998.4	PAKDD98	Melbourne, Australia	110:31	120
1998.8	KDD98	New York, USA	247:68	773
1999.4	PAKDD99	Beijing, China	158:66	150
1999.8	KDD99	San Diego, CA	280:27	600

其研究的重点也逐渐从发现方法转向系统应用，注重多种发现策略和技术的集成，以及多种学科之间的相互渗透。从理论及所开发的应用系统上来看数据挖掘工作是建立在研究者先前使用的方法学和算法之上，特别地，研究者们利用如下一些领域的思想^[18]：①来自统计学的抽样、估计和假设检验，②人工智能、模

式识别和机器学习、建模技术，(3)进化计算、信息论、信号处理、可视化和信息检索。在融入了以上学科的理论与技术之后数据挖掘技术就因此诞生。它将传统的数据分析方法与处理大量数据的复杂算法相结合。在功能上不仅能用来探查大型数据库，发现先前未知的有用模式，还具有预测未来观测结果的能力。在现实中为探查和分析新的数据类型以及用新方法分析旧有数据类型提供了不可多得的机会。图 1 展示了数据挖掘与其他学科领域之间的联系。




图 2.1 数据挖掘与其他领域的联系

Fig2.1 Data mining and the other areas of contact

2.2 数据挖掘的任务与方法

2.2.1 数据挖掘的任务

数据挖掘就是从大量的、有噪声、不完全的、模糊的、随机的数据库中，提取隐含在其中的、人们预先不知道的、但又是潜在有用的信息和知识的过程。^[19]从概念中可以看出，数据挖掘的任务就是从一大堆数据中寻求某种有意义的信息模式或领域知识。通常情况下根据人类发现信息的目标可将数据挖掘任务分为两个大类：预测任务（Predictive）和描述任务（Descriptive）^[20-21]。

①预测任务

预测任务的目标就是根据其他属性的值，预测特定属性的值。在其过程中被预测属性一般称目标变量（target variable）或因变量（dependent variable），而用来做预测的属性称为说明变量（explanatory variable）或自变量（independent variable）。预测任务功能可分为分类（Classification）、预测（Prediction）和推估（Estimation）。预测和推估是数据挖掘中广泛运用的一种功能。数据挖掘的功能在解决实际问题时，并非完全单独使用，不同的问题适用于不同的方法；更多情况是需要同时采用多种数据挖掘方法才能挖掘潜藏的信息。但值得注意的是在数据挖掘实务操作过程中，要建立良好的预测模式流程应注意以下几点：1）数据的选择：预测模式的最终目地是利用现有已经知道的值来预测未来值，因此，选择合适的数据库建立模式是必要和关键的。2）模式检测和评估：建构预测模式时，只用部分数据来建立最初模式，剩余的数据用作测试和评估，这样数据可分为：训练集、测试集和

评估集。

3) 预测模式的适用性：一种预测模式并不是通用的，在进行预测时必需采用适合自身的预测模式，否则即使预测模式很好，但不适用也难以达到预计的效果。

②描述任务

描述任务 描述任务的目标就是导出概括数据中潜在联系的模式。包括（相关、趋势、聚类、轨迹和异常）。本质上，描述性数据挖掘任务是探查性的，并且常常需要后处理技术验证和解释结果。描述任务功能分为关联分析和聚类分析。

2.2.2 数据挖掘方法

数据挖掘的方法有多种，且同一个挖掘方法有多种不同的挖掘算法，在实际应用中应该针对不同的问题采用不同的挖掘方法，在这里本文将简单介绍数据挖掘常用的几种方法：关联分析、聚类分析、预测建模、异常检测。

关联分析（association analysis）关联规则反映一个事物与其他事物之间的相互依赖性 or 相互关联性，是用来发现描述性数据中强关联特征的模式，所发现的模式通常用蕴含规则或特征子集的形式表示。由于搜索空间是指数规模的，关联分析的目标是以有效的方式提取最有趣的模式。^[22]在数字图书馆中积累了大量读者对资源的历史访问数据，可以考虑采用关联规则分析技术，对读者、资源以及读者对资源的访问数据进行分析挖掘，从中发现读者兴趣和资源之间的关联。从而对读者开展个性化推送服务。例如，在数据结果集中我们发现许多读者在借阅了文献A的同时也会借阅文献B，那么在以后的读者借阅当中对于借阅了文献A的读者我们可以对他们推荐文献B。最早最经典的关联分析算法是Agrawal在1993年提出的Apriori算法^[23]。该算法是一种基于候选集的算法，其对关联规则算法的后续研究有着重要的意义。在以后的时间里越来越多的研究团体与学者开始关注与研究，在2000年Han提出了一种新的算法理论—频繁模式增长算法（FP-growth）。这种方法彻底摆脱了Apriori算法生成候选集的方式，建立了基于FP_tree频繁项模式的无候选集的结构思想，开辟了挖掘关联规则的新思路^[24]。

聚类分析（cluster analysis）旨在发现紧密相关的观测值组群，使得与属于不同簇的观测值相比，属于同一簇的观测值相互之间尽可能类似。在具体的推荐系统应用中，聚类就是将用户根据其各自的属性特征进行分类划分，使得同类用户之间相似性尽可能大，不同类之间相似性尽可能小。在图书用户的分类方面可以有多种选择：用户的借阅偏好、兴趣爱好及用户的属性特征。对于聚类的技术有许多文献中都有过介绍，其中比较优秀的有^[25-28]：K-mean algorithm、Genetic algorithm-base clustering technique及其他改进技术。在聚类技术应用于个性化推荐上时其推荐质量不高。^[25-26]因为其通过聚类产生的群或类之间的属性值的相似性并不是很精确，同时一个类内可能会有成千上万个用户，要根据一个群内所有个

体产生的一种兴趣模式涵盖每一个人的偏好是不合理的。

预测建模（predictive modeling）利用历史数据找出一定的规律，建立预测模型，在数学及统计学上讲就是以说明变量函数的方式为目标变量建立模型。其关键的问题是精度与不确定性，通常用预测方差来度量。有两类预测建模任务：分类（Classification），用于预测离散的目标变量；回归（regression），用于预测连续的目标变量。在数据挖掘技术当中用于预测的分析技术包含：回归分析、时间序列分析和人工神经网络（Artificial Neural Network）等^[29]。由于数据结构及其形态的不同，所采用的预测分析技术不同，表2.2对预测模式及其所处理的数据形态进行了说明。

表 2.2 预测模式与其处理数据形态说明

Table2.2 The explain of Prediction model and Processing data form

预测模式	数据说明
回归分析	研究自变量（Independent variable）和应变量（dependent variable）的关系,寻找两个或两个以上的变量之间的相互关系。自变量通常是连续数值，如为类别变量可采用逻辑式回归分析模式。
时间序列分析	以现有数值预测未来数值，所分析的数值都与时间有关。
人工神经网络	主要目标是发现和预测数据的天系，与传统统计方法的区别在于可以训练学习发现的关系，并且适用于线性和非线性的数据；此外，针对质量不佳的数据，也能发现质量最不错的信息。

预测建模在实际的应用中也非常广泛，其中以电信业、银行业及零售业居多。在电信业中常用预测模式有话费量预测、客户呼叫模式分析、客户流失分析等；银行业常用的预测模式有信用风险评估、客户欺诈、客户消费模式等；零售业常用的预测模式有营业收入预测、客户消费行为、商品销售量预测等。

异常检测（anomaly detection）任务是识别其特征显著不同于其他数据的观测值。目标是发现真正的异常点，而避免错误地将正常的对象标注为异常点。其思想最早是由Denning提出并建立一种独立于任何特定的系统、应用环境、系统弱点的检测模型。^[30] 异常检测在实际应用中也十分广泛，都包括：欺诈检测、入侵检测、生态系统失调、公共卫生、医疗等方方面面。

2.3 数据挖掘的过程

2.3.1 数据挖掘的环境

数据挖掘是指一个完整的过程，该过程从大型数据库中挖掘先前未知的，有

效的，可实用的信息，并使用这些信息做出决策或丰富知识。数据挖掘环境可示意如下图2.2：




图 2.2 数据挖掘环境框图

Fig2.2 Data mining diagram of the environment

数据挖掘所处的环境就是指能开展数据挖掘的所有对象的总和，包括：数据库（为数据挖掘提供数据支撑），挖掘工具则是开展数据挖掘的核心，缺少挖掘工具则无法实现其目标，可视化工具是帮助人类理解的一种辅助性工具，因为其处理数据量庞大，其结果也均由数据组成，人类单用肉眼很难从中发现数据结果所表示的意思。最后则是人类的解读及其实现目标的后续工作。

2.3.2 数据挖掘的过程步骤

数据挖掘是一个多过程阶段，一般情况下，它主要分为三个阶段，即：数据准备、数据挖掘、结果分析。数据挖掘过程则是这三个过程的反复循环，如图2.3所示：




图 2.3 数据挖掘过程图

Fig2.3 Data mining process maps

过程中各步骤的大体内容如下：

在完整意义上讲，在数据挖掘之前我们首先要确定业务对象，所以我们在描述数据挖掘的过程步骤时将业务对象的确定先放在第一位。

①确定业务对象：清晰地确定出业务问题，认清数据挖掘的目的是数据挖掘的重要一步。挖掘的最后结构是不可预测的，但要探索的问题都是带有预见性的，不能为了数据挖掘而进行数据挖掘，那样是带有盲目性，将不会成功。

②数据准备：1) 数据的选择，搜索所有与业务对象有关的内部和外部数据信

息，并将适用于数据挖掘应用的数据选择出来。2) 数据的预处理，确定研究数据的质量，为下一步的分析做准备，同时确定将要进行的挖掘操作的数据类型。3) 数据的转换，将数据转换成一个分析模型。这个分析模型是针对挖掘算法建立的。建立一个真正适合挖掘算法的分析模型是数据挖掘成功的关键。^[31]

③数据挖掘：对已经处理过的数据进行挖掘。除了对挖掘算法的选择再进行完善以外，剩下的其他工作都可以自动完成。

④结果分析：解释并评估结果。在分析方法的选择上应该根据数据挖掘的操作而定，可视化技术是一般情况下都会用到的技术。

在数据挖掘中被研究的对象是整个过程的基础，它驱动了整个数据挖掘过程，也是检验最后结果和指引分析人员完成数据挖掘的依据和顾问。步骤是根据一定的顺序完成的，当然整个过程中会有一些步骤间的反馈。数据挖掘的过程并不是自动的，绝大多数的工作需要人工完成。且在数据挖掘过程中的时间分配其中数据准备工作就占用了整个工作的60%的时间，这说明了数据挖掘对数据的严格要求，而后挖掘工作仅占总工作量的10%。

2.4 数字图书馆个性化信息服务

2.4.1 数字图书馆个性化信息服务概述

现代社会的发展，使得信息需求量越来越大，针对用户个人的信息使用行为，习惯、兴趣、爱好特点及用户的信息需求越来越多，这就引发了高校图书馆的个性化信息服务，在概念上我们把其定义为以用户为中心，在研究用户行为、兴趣爱好和习惯的基础上，根据用户的个性化需求而开展的信息服。其最终目的是为用户提供所需的各种信息资源和服务，特点是个性化和主动性，根据用户的行为习惯、兴趣爱好的不同而不同。数字图书馆的个性化信息服务应该满足两方面的条件，首先应该能够满足用户的个体信息需求，通过对用户提出的需求进行分析，主动的组织信息资源向用户进行推送。其次，个性化信息服务应该是一种引导需求、培养个性的服务，可以帮助个体发现个性，同时促进社会的多元化与多样化。在个性化信息服务的实现过程中有两个重要的环节：一是根据信息个体的需求，构建个性化用户模型；二是根据已经建立的模型，以全部信息资源为整体范围，将用户的需求信息从中抽取出来，从而建立与用户匹配的个性化信息集合。在这个信息繁杂的时代背景下，开展个性化信息服务不仅能够减少信息过载，同时也缩短了用户获取信息的时间，从而提高用户的学习和工作效率。因此开展个性化信息服务在人类社会发展中起着重要的意义。

纵观国内外，许多数字图书馆都推出了各自的个性化信息服务系统。从广度和深度上看，服务形式各有不同，服务效果各有长短。综合分析，这些服务在很

大程度上提高了数字化资源的利用率，并呈现出许多更具有发展潜力的特点。①服务方式个性化：传统信息服务“以一适全”的模式无法有效地满足用户的个性化信息需求。而个性化的信息服务系统通过对用户特征的分析、交流与反馈为用户提供个性化的信息内容和系统服务。而用户的各种个性化特征和需求则为该系统的服务方向与措施提供导向。②信息提供知识化：个性化信息服务强调将信息向知识转变，以及隐性知识的挖掘和显性转化。建立以知识为主要内容的服务体系，且其提供的知识化、个性化服务能够提供能决策支持、科学研究和解决问题。③服务手段智能化：个性化信息服务系统是利用各种智能化信息技术，如个性化定制、数据挖掘、人工神经网络等提供智能化的信息服务^[33]。数字图书馆个性化服务系统会对用户的检索知识和经验的相对不足作充分考虑，能够深入的理解用户的智能化信息服务手段。Agent 智能代理技术就是目前能实现数字图书馆的智能化服务的重要技术之一。它能够时实跟踪用户的整个信息活动，且自动捕捉用户的兴趣爱好，自动搜索用户感兴趣的信息并提供给用户。

2.4.2 数字图书馆个性化信息服务的方式

①信息推送服务

个性化信息推送也叫个性化推荐，是指根据用户的兴趣和特点，推荐用户感兴趣的信息资源。其采用推送技术（Push Technology）来实现一种个性化主动信息服务方式。早期有三个最为经典的系统，分别为卡内基·梅隆大学的罗伯特·阿姆斯特朗（Robert Armstrong）等人在1995年3月的美国人工智能协会（American Association for Artificial Intelligence, AAA）上提出了个性化导航系统^[34]、斯坦福大学的马可·巴拉巴诺维奇的LIRA（Learning Information Retrieval Agents）系统^[35]及亨利·利伯曼（Henry Lieberman）等人提出的个性化导航智能体Letizia^[36]。就目前的研究和应用来看我们可以把个性化推送服务分为两个大类：一类是智能软件完成的全自动化的信息推送服务；另一类是借助电子邮箱并有人工参与的信息推送服务。从过程中讲，它实现了从“人找信息”到“信息找人”的一种转换，即信息传播从传统的Pull模式（用户找信息）向Push（信息找人）的一种转变，这样一来，用户就不必再进行任何检索行为，就可以获得自己感兴趣的信息资源。其特点就是用户一次注册登录，填好自己的兴趣爱好，系统就会根据你的信息进行学习，将你感兴趣的信息实时的发送给你。并在随后的过程中学习更新，随着用户的兴趣转移而自适应更新用户的兴趣知识库，以备给用户提供更准确的个性化信息服务。其具体的工作流程如图2.4。




图 2.4 信息推送示意图

Fig2.4 Information push schemes

②信息分类定制服务

分类定制是指信息用户可以按照自己的目的和需求，在某一特定的系统功能和服务形式中，自己设定信息的资源类型、表现形式，选取特定的系统服务功能等。依目前的形式来看，分类定制的服务仍然是数字图书馆信息服务的主流。分类定制的方法是建立在用户细分和数字图书馆数字信息内容分类及定制的基础上。其原理就是数字图书馆根据用户的注册信息，将用户的兴趣爱好提取出来，进行分析归类，一般情况下用户的爱好以关键词的形式产生，这些关键词都可以在中国图书馆分类法中可以进行详细分类，大至有5大部类和22个基本大类。这样就可以将用户划分为多个具有相似性信息需求的用户群，然后根据各用户群的需求情况对馆藏的信息进行大的分类，形成多个资源服务模板，将用户定制目标集中到模板上。这样形成一个类对应类的模式，即某类信息资源对应的服务于某类群体用户。从而当用户进入系统后，服务器可以根据用户的对应关系将查询结果主动递送给用户。目前网络门户“MyYhoo”是较早地运用分类定制的思想为用户提供个性化信息服务的最好例证。

③信息智能代理

代理技术就是在用户没有明确具体要求的情况下，能根据用户的需求，代替用户进行各种复杂的工作。^[37]该技术能够不需要用户的干预和指导，采用智能计算机系统，模仿人的行为执行一定的任务，通过跟踪用户的信息活动，自动捕捉用户的兴趣爱好，搜索那些用户可能会感兴趣的信息并主动向用户提供。这样一来就可以满足那些在检索信息时无法清楚地知道自己的兴趣爱好和需求的用户。

④信息垂直门户服务

垂直门户是通过汇聚网上某一特定专题信息资源，并对其进行挖掘及加工，以满足用户基于专业的信息需求。这一概念是与综合性门户及水平门户相对应，在这一方面的应用有中国化工网、中国医药信息网、中国工程技术信息网等。垂直门户服务的优点是可以有效地把对某一特定领域信息感兴趣的用户与其他用户区分开来，更能满足用户的特定信息需求，从而提供个性化的高质量的信息。

⑤个性化检索服务

个性化检索是指根据用户的需求特点进行检索，返回的检索结果应与用户的需求相关，即利用信息过滤技术，让不同的用户在使用相同检索策略的情况下，根据用户的不同能够检索出适应于每个用户需求的检索结果。目前，更多的是对用户检索行为特点的研究设计出相应的检索智能帮助软件不向用户提供此类服务。

⑥数据挖掘服务方式

数据挖掘服务方式是指从数据库、数据仓库和浩瀚的网络信息空间（在图书馆中即为图书馆数据库）及读者的历史访问信息中，通过运用数据挖掘（DM）和联机分析处理（OLAP）技术来识别借阅信息、读者行为、读者兴趣等相互之间的关联，而这种关联不仅对用户是有用的，对图书馆决策层也是有用的，在这些有用的信息中从而发现新的知识或用户行为模式，来为读者开展个性化服务。从应用角度划分，数据挖掘技术可分为两类：一是面向数值数据的数据挖掘（Data Mining）；一是面向文本信息的数据挖掘，文本挖掘（Text Mining）。它们采用直观的图形方式将信息模式、数据的关联趋势呈现给信息用户（决策者），决策者可以通过可视化技术交互地进行数据分析。

⑦信息呼叫中心服务方式

信息呼叫中心是一种新近发展起来的专门提供一对一的用户个性化信息服务系统，在企业界有着广泛的应用。它的发展从最初的利用电话、传真来服务客户，逐步地引进计算机电话集成技术（CCT），不仅能够处理复杂的呼叫流程，并且还增设了自动话务处理、交互式应答等多种功能^[38]。在数字图书馆中其信息呼叫中心借鉴了企业的呼叫中心（客户关系管理），建立了客户数据库，使呼叫中心可以联系到每一个客户，了解每一个客户，并且可以根据对数据库中的客户信息资源进行分析为客户提供一对一的个性化服务。

2.5 国内图书馆自动化系统及分类法简介

我国图书馆自动化系统的研究始于上世纪70年代中期，当时只是针对国外引进的单功能系统的改进与研究，随后80年代中期国内开始大力加强自主研究，以摆脱对国外系统的依赖，直至90年代中期，我国图书馆自动化系统建设取得了成效，出现了以北京丹诚图书集成管理系统为代表的采用C/S模式二层结构的系统^[39]。至此图书馆自动化系统才以基本形成功能齐全的成熟产品进入市场。以后随着国外自动化系统技术发展的潮流，我国进行了广泛的研究。目前我国高校图书馆采用的系统包括：汇文、ILAS、金盘、清大新洋、图腾、妙思、北京邮电大学自主研发的MELINETS、HORIZON、INNOPAC、美国的UNICRON、ALEPH等。其中国内以北京邮电大学图书馆的MELINETS为代表，在全国范围内拥有着广大

的用户。

重庆大学图书馆于2006-2007年历经可行性论证、系统需求分析、系统开发到系统验收，自主开发出了功能强大的“ADLib2.0现代图书馆管理系统”。该系统以提高文献管理和文献服务水平为目标，全面集成了基于馆员的业务工作和内部管理工作、及基于读者的知识服务系统。在读者服务方面可以自建数据库资源建设，为读者提供个性化服务，并且通过“我的图书馆”实现资源共享，同时开展虚拟参考咨询服务。该系统在构架方面集管理、资源、服务于一体，构建出12个子系统模块，并且在管理方面分别设有：馆员管理、读者管理、资源管理。在知识服务方面除了开展一键式资源检索，还开展了“我的图书馆”个性化服务系统。在“我的图书馆”中分有8个服务模块，包括：借阅情况、文献搜索、我的数据库、建议与咨询、推荐图书、电子定单推荐、申请离校、兑换申请。在对“我的图书馆”的实际应用中我们可以发现，该服务系统并没有实现完全意义上的个性化服务，在个性化服务方面有两方面含义，一是个性化，二是主动性。而在该服务模块中很少有突出主动性服务功能，因为在“推荐图书”模块中，可以知道，该模块的推荐功能是读者与读者之间的一种推荐行为，而并非是图书馆对读者的一种推荐行为。这种推荐质量或许并不是想象中的那么好，因为，在读者与读者之间，每位读者的兴趣爱好，行为习惯、专业背景及研究发向在很大程度上决定了读者的借阅偏好，即是一种自我主动推荐，并没经过分析其他读者的借阅信息而再给予推荐。因此图书馆作为服务方应肩负这种责任，利用庞大的数据基础并结合现代数据分析技术——数据挖掘，经过对读者借阅纪录的深度挖掘，找出读者的借阅规律与模式，科学的向读者进行推荐，实现完整意义上的个性化服务。在个性化服务方面，不仅重庆大学图书馆自主研发的“ADLib2.0现代图书馆管理系统”没有数据挖掘分析功能，上文所述的国内高校采用的其他图书馆自动化系统也没有数据挖掘功能。

数据挖掘的展开需要数据基础，而在图书馆当中挖掘的图书信息涉及到图书分类法，我国大部分高校都采用《中国图书馆图书分类法》，重庆大学亦是如此，只有中国人民大学采用自主编制的《中国人民大学图书馆分类法》。所以在对图书馆的各类数据进行预处理之前，需要对中国图书馆图书分类法进行简单的介绍。

《中国图书馆图书分类法》简称《中图法》^[40]是我国建国由中国图书馆图书分类法编辑委员会编制出版的一部具有代表性的大型综合性分类法。是当今国内图书馆使用最广泛的分类法体系，初版于1975年，以1999年出版的第四版后正式改名为《中国图书馆图书分类法》。为适应不同图书信息机构及不同类型文献分类的需要，它还有几个配套版本：《中国图书资料分类法》、《中国图书馆图书分类法（简本）》和《〈中国图书馆图书分类法〉期刊分类表》等。目前该馆使用的是《中国图书馆图书分类法》第四版，包括“马列主义、毛泽东思想，哲学，社会科学，

自然科学，综合性图书五大部类，22个基本大类”53811个类目（包括专用和通用类目）。其基本大类如下表2.3所示：

表 2.3 中国图书分类法简表

Table2.3 Chinese library classification

五大部类	22个大类
马列主义、毛泽东思想 哲学	A 马克思主义、列宁主义、毛泽东思想、邓小平理论
	B 哲学、宗教
社会科学	C 社会科学总论
	D 政治、法律
	E 军事
	F 经济
	G 文化、科学、教育、体育
	H 语言、文字
	I 文学
	J 艺术
	K 历史、地理
	N 自然科学总论
自然科学	O 数理科学和化学
	P 天文学、地球科学
	Q 生物科学
	R 医药、卫生
	S 农业科学
	T 工业技术
	U 交通运输
	V 航空、航天
	X 环境科学、安全科学
综合性图书	Z 综合性图书

3 数字图书馆个性化系统模型设计

3.1 数字图书馆个性化系统设计背景

重庆大学图书馆于2007年已经开发出“ADLib2.0现代图书馆管理系统”，该系统是基于Internet环境运行，通过使用先进的Flex技术来实现，丰富了图书馆自动化系统的功能，先进的管理模式实现了真正意义上的馆际互借，支持决策管理系统的应用，能够全方位地为图书馆业务监控和决策提供参考依据并能实时引导读者阅读倾向，实现了读者的个性化需求，具有先进的开发平台和数据库支撑平台，如DB2、ORACLE、SQLSEVER、MYSQL等，基于强大的数据库开发平台为个性化服务中的数据挖掘技术服务方式提供了技术支撑。

基于对该系统的具体分析，发现其在个性化服务方面做的不够好，只体现出个性化服务中的个性化，而对于主动性这一特性并未涉及到，基于此，本文的目的是在现使用的“ADLib2.0现代图书馆管理系统”基础上设计一个基于数据挖掘个性化服务模型。通过对读者借阅信息和书目信息数据的收集、加工和处理，利用个性化服务模型分析读者的借阅需求、兴趣和习惯，进而可以推测读者的未来借阅行为，最终从真正意义上实现个性化信息服务的目的。^[41]

3.2 数字图书馆个性化系统设计目的和思路

目前各类网站数量众多，信息资源总量庞杂，信息增长飞快，为了能让用户在繁杂的资源信息中能够快速便捷的找到适合自身的资源，且能够投其所好，提供个性化的信息需求，各类网站相继开发个性化推送系统。如Joyo、BOL等，都有各自的推荐系统。其中Amazon（亚马逊网）是最早开展个性化推荐功能的服务网站，也是世界范围内做用户个性化推荐服务的一个典范。其特点是综合了多种推荐服务类型，基于产品相似性和相关性，基于浏览/购买历史，基于协同过滤等方式。根据Haubl和Trifts研究调查发现，有推荐系统时，93%的消费者选择了更优的产品，而没有的情况下，做出这样选择只有65%^[42]。本文拟采用数据挖掘技术，结合高校图书馆读者借阅历史、馆藏特点，依托重庆大学图书馆现有的ADLib2.0现代图书馆管理系统等因素，突破图书馆个性化推荐的普通形式，致力于数据挖掘的个性化推荐系统研究。

3.2.1 设计目的

高校图书馆与公共图书馆相比，它有着自己的特点，在读者对象方面主要是高校教师和学生，还包括其他职工人员及其少量的外单位人员。在馆藏书目种类上来看，公共图书馆的馆藏量及种类或许较之高校图书馆多，究其原因，公共图

书馆的服务对象是广大社会群众，要满足其需求必需在馆藏的种类与数量上要广而多。而高校图书馆的服务对象则是高校师生，其收藏图书的专业性比较强，这依赖于高校的当下的课程设置和发展定位，以重庆大学为例，因其在早些时期以机电、能源、材料、信息、生物、经管等学科为主，所以学校图书馆的藏书多以工科类为主，对于人文、艺术、教育等学科的参考书籍就相对比较少。目前，各类高校图书馆向学校师生提供书籍各类的依据来源于两个方面：一方面是根据系统中所显示的各类书籍的借阅量分布情况；另一方面是根据流通部门工作人员的描述及采购部门的经验。而在各高校中，不同专业的师生除了习惯、教学科研与研究方向不同以外，他们还有各自的兴趣爱好，因此高校图书馆应该针对每个师生的不同的兴趣爱好及需求进行有针对性的个性化推荐服务。所以基于数据挖掘的个性化系统的设计目的就是要充分挖掘高校图书馆大量的读者借阅历史数据，从挖掘结果中分析出读者的借阅行为模式，兴趣需求及各学科之间的关联性，为高校图书馆向读者提供个性化服务及其建立合理的馆藏结构提供有力的科学依据。极大的深化高校图书馆的服务层面。

3.2.2 设计的思路

①构建原则

数字图书馆个性化推荐系统设计开发应该从用户与读者角度出发，且其最终也是为读者的应用和管理人员的管理而建立的，因此在设计时应该考虑以下几方面的原则：

1) 易操作性

高校图书馆的主要群体分为两类，一类是教师；另一类即是学生，两类群体的知识水平与技能均不相同，这就决定了他们操作时的感受不同，对于绝大部份的用户来说均属于普通类型的读者，对他们来说，则喜欢简单快捷的操作，因此在设计时应该考虑读者的各种需求，如果个性化服务的定制步骤比较繁琐且浪费时间，读者很容易放弃这种个性化服务。所以在设计时应该遵循操作的简单性，即易于读者操作。

2) 完整性

基于数据挖掘技术的个性化服务需要数据的支撑，数据越是详尽，则挖掘出的结果质量越高。对于重庆大学图书馆来说，其在读者信息的完整性上欠缺其每位读者的专业信息，这就对于以后挖掘工作有所不便，因此系统在提取读者的信息时尽可能包括：姓名、性别、出生年月、学号、院系、专业、研究方向、感兴趣的主体（这此主题可以是文字类，也可以由系统向读者提供中图法类别的筛选）等信息。

3) 可更新性

随着时间的推移，读者可能在兴趣爱好上有所变化，且其需求也会跟着发生

变化，所以这就要求系统能够实时更新。

4) 安全性

系统内存储着读者及用户的个人基本信息，这些信息则属于读者的个人隐私，其在没有经过读者的个人允许下是不能够传给他人，如果其个人信息遭到泄露，会对读者造成影响。所以系统在设计上要确保其安全性。

②各类资源的分析

1) 读者细分—聚类分析

读者细分源于客户细分这一概念，是美国市场学家温德尔史密斯（Wendell R. Smith）于 20 世纪 50 年代中期提出来的^[43-45]。引入读者细分就是在分析读者借阅模式前，根据现有条件下的数据类型，在明确的目标下，根据读者的历史借阅纪录、读者属性等因素对读者进行分类。分属同一类群体的读者具有一定程度上的相似性，而不同的读者群体之间存在明显的差异性。从而针对不同的细分群提供不同的服务和推荐模式。典型地说，读者细分的建立，是要采用一种无人管理的学习算法或聚类分析来实现，因为人工决定的读者细分并未从潜在的知识情况出发，忽略了读者的兴趣爱好等信息。

2) 馆藏图书分析

高校的藏书非常多，但是并不是每一本书都会被读者所光顾，其中有些书籍被借阅的次数较多，而有些图书则一直无人访问。统计分析图书的借阅频次也是向读者提供个性化服务方式之一，可以根据细分的读者群内借阅频次比较多的图书推荐给被划分为这一类中的新来读者。同时也可以将馆藏中的前 10 个最热门的图书推荐给每个读者。

3) 图书关联性分析

关注读者行为模式的关联规则分析，根据读者的借阅历史纪录，找出读者的借阅模式，从而根据该模式向读者提供个性化推荐服务。比如，在数据库集中，发现大部份读者在借阅了“计算机应用”的同时也借阅“算法语言”这本书。从而推出，这将是读者的借阅模式，而这两本书之间就存在着某种关联性。根据这一情况，如果有其他读者借阅“计算机应用”时，我们可以向其推荐“算法语言”这本书。

3.3 个性化系统结构模型设计

3.3.1 整体结构模型

本文所设计的个性化服务系统模型如图 3.1 所示，本结构图是根据用户从网站注册到最终的个性化服务的提供为基本流程，即从用户信息的采集，然后利用相关技术对整体用户根据其信息属性进行用户建模，最后将用户所构建的模型与已生成的知识库（规则库）进行匹配进而向用户提供个性化信息服务。




图 3.1 基于数据挖掘的个性化系统结构图

Fig3.1 Data mining personalized system structure

图 3.1 中主要分为两大模块，一是在线推荐模块；二是离线挖掘模块，分别以实线图与虚线图进行表示，而知识库中知识的获得由资源采集层、资源加工处理层、资源存储层和资源服务层组成。其中资源采集层、资源加工处理层、资源存储层为服务层的知识推送服务提供数据基础。该系统中数据采集来源于数字图书馆中的那些零碎的数字信息，包括：读者基本信息、读者借阅历史记录、检索历史记录以及图书馆中的馆藏资源信息，最后要经过资源处理层的加工，实时更新数据库信息，保证资源数据的时效性。知识资源获取结构如图 3.2 所示。




图 3.2 知识资源获取结构

Fig3.2 The structure of knowledge acquisition

在资源采集层中，信息采集的方式分为两种，一类是自动采集，即系统根据读者在图书馆借阅时所需的借书证在刷卡时自动提取读者的个人信息，并将其保存在读者信息库中；另一类则是手工采集读者信息，这一原因是由历史系统遗留的问题，在以前，由于系统问题，读者借书证中对于读者的个人信息记录并不完全，只保有读者姓名及学号等信息，而对于读者的专业、研究方向等信息并未输入，这就需要工作人员在读者借书时，根据系统显示情况而补充读者遗缺的信息。在资源处理层当中，就要对不规范的数据进行清理、格式转换等操作，将其转换成数据挖掘可识别的数字信息，最后经由数据挖掘工具将其转换为知识——规则集，将其进行存储并向读者提供服务。

3.3.2 功能描述

个性化推荐系统的基本功能模块主要包括：

①收集用户信息的行为记录模块

该记录模块主要包括两个部分：图书信息采集模块和读者信息采集模块。在图书信息采集模块中主要是向后期数据处理时提供全面的图书信息，主要包括图书的题名、索书号、中国图书馆分类号、作者、出版等情况，并可以在借阅及推荐阶段向读者提供详细的图书信息，以供其参考。而读者信息采集模块主要是收集读者的个人注册信息及能够全面描述读者个性的其他属性信息。

②用户模型分析模块

该模块主要功能就是生成用户模型，即根据对上述所采集的信息进行分析，按其所隐含的规律将读者进行划分，根据划分情况找出读者借阅行为模式。

③推荐模块

推荐模块是最核心的部分，根据推荐算法的不同，推荐系统可以分为如下几类：协同过滤（collaborative filtering）^[46]；基于内容（content-based）的推荐系统^[47]；混合（hybrid）推荐系统^[48]及基于规则的推荐系统^[49]，本文采用的是基于关联规则的推荐，因为在图书馆中存在着大量的借阅数据，而这种类型的数据只有一个特征，即哪些读者借阅了哪些书籍，在书籍与读者之间只存在借阅与否的问题，并无其他形式的内容存在。而其他推荐系统算法，如协同过滤、基于内容等系统的算法的思想是利用用户的历史信息计算用户之间的相似性，而这种相似性依赖于用户对图书的评价及打分情况来预测目标用户对特定产品的喜好程度，再根据喜好程度对目标用户进行推荐。在本图书馆中，并不存在读者对书籍的打分情况，所以无法获取数据源，因此采用基于关联规则的推荐具有可行性。该模块利用此算法得出读者借阅书籍的关联集，从而向读者推荐其感兴趣的书籍。

通过以上三个模块的分析，个性化服务系统就可以在真正意义上实现对读者的个性化服务，将个性化服务的个性化与主动性能全部体现出来。这种功能能在

读者还没有明确需要的资源时，根据读者的借阅历史记录及其他反应读者的属性来预测读者的借阅行为和兴趣爱好，从而个性化地为读者提供服务。

3.3.3 工作流程

总的工作流程，将从两方面展开，第一是从读者方面，第二是图书馆的后台数据方面进行。

首先，读者根据自身的注册信息及账号进入个性化界面，与系统进行交互，在此过程中读者可以查阅各类书籍信息，同时可以接受系统的个性化推荐。此外，个性化系统后台将调取读者的个人特点及其他借阅信息，对其进行归类，分析出其借阅行为模型，最后采用关联挖掘找出强关联资源并向读者进行推荐。工作流程图 3.3 如下：




图 3.3 系统工作流程

Fig3.3 The work flow of system

3.3.4 个性化推荐模块的组成

在个性化推荐中，根据其时效性要分为两种，即是前面提到的在线推荐模块和离线挖掘模块。其中离线挖掘模块是为在线推荐模块提供服务，而在线推荐模块又可向离线挖掘模块提供数据基础，两者缺一不可，共同组成基于数据挖掘技术的个性化推荐模块。只是分工不同而已。离线模块是对用户进行聚类细分，找到相似群，建立用户模型，再对大量的借阅记录进行挖掘生成强关联规则。而在线推荐模块不仅完成信息的采集，同时根据用户的注册信息与知识库进行匹配，找出用户所属类群，然后生成关联规则向用户进行推荐。

采用离线挖掘不仅在数据处理上具有科学性，在时间效度上具有合理性。因为，在图书馆中存储着大量的借阅数据，不仅每天都会有更新，而且在对数据的处理方面还要花费大量的时间，所以在线对其进行挖掘分析可行性不高，所以该模块的工作模式采用离线处理模式。离线处理的结果并不会影响推荐的结果质量，因为对于关联规则的生成都是基于大量借阅历史数据（一般都在数以万计以上）的挖掘分析而产生，在短时间内，新增的借阅数据量比较少，与过去的基数相比，对挖掘的结果产生的影响较小。我们可以根据新增数据量的大小对挖掘结果的影

响程度定一个新增数据范围（比如 8000-10000 万条新增记录），再依据新增数据量范围，推算出达到新增数据范围量的时间跨度（比如 3 个月），根据这个时间跨度我们就可以以 3 个月为一次处理时间，对数据进行挖掘，从而更新规则库即知识库。所以，关联规则的离线挖掘既具有科学性又具有合理性。

离线数据挖掘生成强关联规则流程图 3.4，需要以下三个主要功能部分组成：

①数据预处理模块，即数据存储，数据主要来源于图书馆系统数据库中，并对原始数据进行处理，之后将其存储在数据挖掘库中。

②挖掘模块，即数据挖掘的引擎，主要涉及了数据挖掘的算法，运用聚类及关联规则对预处理的读者信息及其借阅数据进行数据挖掘，生成读者相似群及规则。

③规则导入模块，将其挖掘的结果集（知识）进行结构化存储，写入到规则库中（知识库），供推荐的使用。




图 3.4 离线数据挖掘生成强关联规则流程

Fig3.4 Association rules generate of Offline data mining process

在线推荐模块，其功能就是实现用户模型与知识库资源的匹配，最终将最适合的结果通过各种方式推荐给用户，完成个性化系统的推荐功能。

4 个性化服务数据挖掘实施

上一章节中，我们从理论分析角度为数据挖掘开展个性化服务提供了基本的框架，但在实际环境中实现它，还需要各种硬件和软件技术的支持。本章节主要工作是针对个性化服务层中的数据处理模块（含数据采集）及数据挖掘模块的具体实现作了详细的研究，进一步实现用户信息行为及知识库的建立，并对挖掘结果提出一些具体的推荐建议。

论文选取重庆大学图书馆的历史借阅记录为研究对象，以 MS SQL Server2008 为基础框架，并采用 SPSS 与 Microsoft SQL server 2008 中的 Analysis Services 挖掘分析工具对数据进行处理及挖掘分析，通过对图书馆数据特征进行分析，确定挖掘属性，选择合适的挖掘方法，对读者进行聚类细分，挖掘关联规则，建立知识库向读者进行推荐。具体挖掘实施流程如图 4.1 所示：




图 4.1 数据挖掘实施流程

Fig4.1 Data mining implementation process

4.1 图书馆数据挖掘数据源的选取

在高校数字图书馆系统中，不仅存储着大量的图书资源供读者使用，同时每天都会产生大量的图书流通数据，也即是读者借阅记录，这些数据除了用于记录读者的借阅情况外，一般情况下只是用来做一些常规的简单的业务统计，而隐藏在这些数据背后的未知的、有价值的、有用的知识却未被人知，而这些知识的发现在很大程度上可以帮助图书馆进行决策，提高读者的到馆率，同时在清楚了读者的借阅行为后可以提高图书馆的服务层面，并能够向读者开展有针对性的个性化的服务。

重庆大学图书馆馆书总共藏书680多万册^[50]，每天的借阅流通量非常大，据统计，去除其他借阅人员如，校外人，其他单位人员及一些职工人员，只统计本科生、硕士研究生、博士研究生和教师，平均一天的借阅量可达3000左右，一年的借阅量在80万左右。在这些数据背后就隐藏着大量的有价值信息，因此，在此基础上，本文选择重庆大学2007年1月到2010年12月的读者借阅数据为个性化服务研究进行实例说明。数据选择的时间跨度为四年是因为对于本科生而言，四年刚好

是读者入学后到毕业的几年的时间是一个完整的阶段，通过对这些读者在大学四年间的借阅行为分析，可以从中看出一批读者在校时间中的表现，通过对这一批人数的观察，可以将其分析结果用于其他与其专业、爱好、兴趣相同的读者。在一定意义上可以预测即将步入大学校园的学生的借阅行为趋势，从而使得图书馆的服务及管理在某种意义上具有前瞻性。

4.2 借阅数据的处理

数据是数据挖掘和分析的基础，若无数据就无挖掘与分析之源^[51]。当然数据准备阶段是整个数据挖掘过程中最费时费力和烦心的事，因为我们获取的数据并不一定都符合挖掘工具处理的条件与格式，这就要求我们对数据进行清理、转换、整理等以便后面工作的正常进行。为能够全面了解读者的借阅情况，且能在以后的工作中顺利进行，需要从图书馆管理系统中抽取三个数据集：读者基本信息、借阅历史信息、馆藏信息。

①读者基本信息：主要用来为用户分类、借阅行为分类聚类提供依据。主要内容包括：读者号，读者姓名，读者类型，所在院系，借阅书证状态等信息，原数据如下图4.2所示：

序号	读者号	读者姓名	登录名	读者类型	所在院系	借书证状态
1	20020345	林莉	20020345	校友	经济与工商管理学院	正常
126	20021189	安丽娜	20021189	本科生	艺术学院	正常
145	200001027	廖屿菡	200001027	教师	建筑城规学院	正常
146	200002036	马利振	200002036	硕士研究生	研究生院	正常
147	20000211	郑伟	20000211	本科生	贸易与行政学院	正常
149	200007028	李秋勇	200007028	硕士研究生	研究生院	正常
150	20000788	叶志平	20000788	本科生	数理学院	正常
151	20000820	谭显建	20000820	本科生	机械工程学院	正常
153	20000911	解大磊	20000911	本科生	机械工程学院	正常
154	20000981	田军	20000981	本科生	机械工程学院	正常
155	20001200	程铖	20001200	本科生	机械工程学院	正常
156	20001414	郑宁	20001414	校友	电气工程学院	正常
157	20001436	刘勇	20001436	本科生	电气工程学院	正常
159	20001534	王平	20001534	本科生	电气工程学院	正常
162	20001825	卢山	20001825	本科生	计算机学院	正常

图 4.2 读者信息表

Fig4.2 The list of Readers' information

②借阅历史信息

这部分信息是利用数据挖掘技术获取图书馆文献利用状况的关键，也是挖掘读者信息行为模式的主要数据源，通过对它的统计、归类、挖掘分析有助于了解

读者的偏好、对读者进行聚类细分建立读者行为模型，原数据如图4.3所示：

序号	索书号	题名	读者姓名	读者号	借出时间
45	F819783	通货膨胀简论	刘灿	20071662	2008-10-30 20:35:23.167
46	F819783	通货膨胀简论	刘灿	20071662	2008-11-26 20:40:37.760
47	TU3319872	板壳理论	贾延杰	20046072	2007-10-23 15:49:15.633
48	TU3319872	板壳理论	付勇	20082002018	2010-03-31 08:52:17.673
49	TU3319872	板壳理论	付勇	20082002018	2010-04-22 10:18:53.557
50	TU3119857	结构风压和风振计...	徐诗歌	20091602155	2010-06-08 16:18:32.957
51	TU9919874	给水工程	黄波	20045512	2007-10-22 16:37:33.453
52	TU9919874	给水工程	黄波	20045512	2007-11-20 21:01:43.290
53	TU9919874	给水工程	方斌圪	20048268	2007-12-25 16:25:17.087
54	TU9919873	给水工程	胡敏	20056358	2008-01-10 12:29:35.190
55	TU9919873	给水工程	何萍	20096652	2009-12-02 11:13:40.523
56	TU9919872	排水工程(上册)	何萍	20096652	2009-12-02 11:13:35.727
57	TU2419872	医院建筑设计与设...	罗旋	20055478	2010-03-30 15:50:52.847
58	TU2419872	医院建筑设计与设...	黄朕涟	20055401	2010-05-04 19:44:40.267
59	TU2419872	医院建筑设计与设...	冯瑾	20055486	2010-03-01 09:47:07.757

图 4.3 读者借阅信息

Fig4.3 The list of Readers' borrowing information

③馆藏信息

这是图书馆最常见的数据集合包括：题名、馆藏号、索书号、馆藏地、入库时间等。这些信息图书馆中都有完整的记录格式，我们只需从中提取出来，但是为了能够和其他表中的信息进行衔接，为以后数据挖掘做准备，有些属性需要概化才能为之所用，原数据如图4.4所示：

序号	题名	馆藏号	馆藏地	索书号
1	物流工程	CQU1379120	新校区社科	F25 2005 9
2	园林制图	CQU1379121	B借书处	TU98 2003 154
3	园林制图	CQU1379122	B中文建筑书...	TU98 2003 154
4	园林制图	CQU1379123	B借书处	TU98 2003 154
5	园林制图	CQU1379124	B借书处	TU98 2003 154
6	C语言程序...	CQU1379125	自科借阅	TP312 2006 141
7	C语言程序...	CQU1379126	新校区自科	TP312 2006 141
8	C语言程序...	CQU1379127	自科借阅	TP312 2006 141
9	C语言程序...	CQU1379128	新校区自科	TP312 2006 141
10	C语言程序...	CQU1379129	自科阅览室	TP312 2006 141
11	C语言程序...	CQU1379130	新校区自科	TP312 2006 141
12	C语言程序...	CQU1379131	新校区自科	TP312 2006 141

图 4.4 馆藏信息

Fig4.4 The list of collection information

在本次数据记录中，在未经处理的情况下，其中读者信息表总共有43,565条记录，借阅信息表共有2,295,154条记录，馆藏信息表总共713,823条记录。

为能够缩短挖掘的处理时间，我们将读者类别，读者所属院系信息均提取出来分作两个表：读者类型表和院系信息表。其表中信息如下表4.1、表4.2所示：

表 4.1 读者类型代码对照表

Fig4.1 Readers type code cross-references

读者类型	类型代码
本科生	bachelor
硕士研究生	master
博士研究生	doctor
教师	teacher

表 4.2 学院名称代码对照表

Fig4.2 College name code cross-references

学院名称	代码	学院名称	代码
贸易与行政学院	01	计算机学院	14
经济与工商管理学院	02	建筑城规学院	15
建设管理与房地产学院	03	土木工程学院	16
外国语学院	04	城市建设与环境工程学院	17
艺术学院	05	化学化工学院	18
数学与统计学院	06	生物工程学院	19
机械工程学院	07	资源及环境科学学院	20
光电工程学院	08	体育学院	21
材料科学与工程学院	09	美视电影学院	22
动力工程学院	10	法学院	23
电气工程学院	11	软件学院	24
通信工程学院	12	文学与新闻传媒学院	25
自动化学院	13	农学与生命科学研究院	26

4.2.1 数据清洗

以上从图书馆管理系统中提取出来的数据记录，是论文及挖掘研究工作最主要的部分，因此，对各部分数据表中数据的正确性、可靠性有很高的要求。因为

数据是数据库备份文件，其存储的形式是以后缀为.backup数据类型，因此本次工作采用SQL Server 2008数据库将该备份文件导入，采用数据库中集成的ETL工具对其进行处理。

①读者信息的清洗

在读者信息表里面的借书证状态中，对于那些已经注销了的用户，可以将其进行删除。而对于那些存在着诸如读者姓名、学院、学号、为NULL的值，以及我们发现在读者信息表中存在着大量读者姓名以及其他有关读者属性值显示不全的情况如图4.6所示，可以依据情况将其补全，比如某用户的姓名在读者信息表中显示为“姚?亮”，可以将其找出，查看该读者的读者号，而读者号在信息表中是唯一的，因此，可以在借阅信息表中根据其读者号进行查找，就可找出该读者的姓名信息。在读者类型中也存在属性相同但其名称不一的现象，比如，有的读者其类型为本科生，而有些读者被存为新区学生，根据重庆大学的学生安排上，新区学生均为本科生，因此，要将其读者类型的取名进行统一处理，即全部归为本科生类别。最后，读者信息表中存储的每位读者应有一条记录与之对应，因此，对于重复记录值应将其删除。具体操作要用到相关SQL语句如下：

```
use cqudata
```

```
select * into cqudata.dbo.tmp from cqudata.dbo.dz where 读者姓名 like '%?%'
```

```
select cqudata.dbo.tmp.序号,cqudata.dbo.tmp.读者号,cqudata.dbo.dzjy.读者姓名,  
cqudata.dbo.tmp.登录名,cqudata.dbo.tmp.读者类型,cqudata.dbo.tmp.所在院系,
```

```
cqudata.dbo.tmp.借书证状态 into cqudata.dbo.tmp2 from cqudata.dbo.tmp inner join  
cqudata.dbo.dzjy on cqudata.dbo.tmp.读者号=cqudata.dbo.dzjy.读者号
```

```
select * from cqudata.dbo.dz where cqudata.dbo.dz.读者号 in ( select  
cqudata.dbo.tmp2.读者号 from cqudata.dbo.tmp)
```

```
update cqudata.dbo.dz set 读者姓名 = cqudata.dbo.tmp2.读者姓名 FROM  
cqudata.dbo.dz,cqudata.dbo.tmp2 where cqudata.dbo.tmp2.读者姓名 = cqudata.dbo.dz.  
读者姓名
```


序号	读者号	读者姓名	登录名	读者类型	所在院系	借书证状态
206	20048658	?	20048658	本科生	应用技术学院	正常
19339	20054686	骆?	20054686	新区学生	自动化学院	正常
19424	20054781	沈寅?	20054781	新区学生	自动化学院	正常
25587	20061775	叶青?	20061775	新区学生	建筑城规学院	正常
36394	20070248	徐?林	20070248	本科生	美视电影学院	正常
36577	20070303006	陈?}	20070303006	硕士研究生	建设管理与房地产学院	正常
39940	20071595028	章向*?	20071595028	硕士研究生	经济与工商管理学院	正常
40412	20071703001	何?U	20071703001	硕士研究生	建设管理与房地产学院	正常
41165	20072043	李?	20072043	新区学生	数理学院	正常
41412	20072267	姚?亮	20072267	新区学生	数理学院	正常
42844	20073528	王?	20073528	新区学生	建筑城规学院	正常
49990	20085901	方?	20085901	本科生	建筑城规学院	正常
50156	20083539	李?	20083539	本科生	光电工程学院	正常
50170	20081257	吴?	20081257	本科生	艺术学院	正常
50185	20081386	王?	20081386	本科生	艺术学院	正常

图 4.5 读者姓名残缺表

Fig4.5 The list of reader's name incomplete information

②借阅信息的清洗

对于借阅信息的清洗是比较关键的一项，因其是挖掘处理的核心数据集，所以对其存在的空值、选择对象一定要符合要求。在读者范围数据的选取上我们只选择本科生、硕士研究生、博士研究生以及教师。而在借阅信息中还有其他人员，如馆内、业余攻读、优异生、外单位、校友、职工等类型。由于这些人员其借阅数据量比较小，且在借阅需求中有各自的特点，难以与学生具有相同的借阅模式，在挖掘时并不需要，因此对于这些人员的借阅信息要将其清除。

③馆藏信息的清洗

处理完毕读者信息及借阅信息表后，接下来要对馆藏信息表进行处理，对于馆藏信息情况并不做太大要求，只需将重复记录进行剔除即可，并对每本书设置唯一索引以便与借阅信息进行关联。

对每个表中的字段进行处理过后，下来应该考虑每个表中的字段保留情况：

在读者信息表中，对于姓名来说，会重复，不能作为唯一标识码，但每位读者均有一一对应的读者号，可以将读者号作为读者信息表中的索引键，用作以后表与表之间的关联。而登录名与读者重复且序号字段并没有反应读者的特征属性，因此可以将其删除。

在借阅信息表中，只有序号反应每一次的借阅情况，因此可将序号字段作为索引键。其他字段不作修改。

在馆藏信息表中，由于对于一本图书来说它可以有不同的索书号，因此应该将题名作为该表的唯一索引。其序号和馆藏地暂不作考虑，因此可以将其剔除。

4.2.2 数据转换

在数据清洗的过程中实现了数据挖掘所需数据的准确性与可靠性，但是数据挖掘要处理的三个信息表中存储字段的形式还不能满足我们的需求，在设定目标的同时，我们需要知道每个读者借阅书籍所属类别，也即是读者偏好的图书类别，因此要根据中国图书馆图书分类法将每本图书进行划分。对于表名、字段名、时间等方面也需做进一步处理，以便于后面工作的展开。

①表名与字段名的统一处理

为了便于处理及提高挖掘处理时间，将每个表名及字段均以单词代替，其对应的相应关系如下表4.3,表4.4所示：

表 4.3 表名对照情况

Table4.3 English-Chinese contrast table name	
源表名	处理后的表名
读者信息表	cqudata.dbo.library_reader
借阅信息表	cqudata.dbo.library_lenddata
馆藏信息表	cqudata.dbo.library_data

表 4.4 字段名对照表

Table4.4 English-Chinese contrast field name	
源字段名	处理后的字段名
序号	id
题名	title
分类号	cl (Library Classification)
读者号	rnum (reader number)
读者姓名	reader
读者类型	rtype
所在院系	rdepart
借阅年份	j_year
借阅月份	j_month
借阅日期	j_day
借阅时间	j_hour
借阅星期	j_week
学院代码	xydm

续上表 4.4:

读者借阅量	number_reader
图书所属大类	dl
图书所属小类	xl
图书所属细类	xxl
图书借阅总次数	number_title

②索书号转换

图书的索书号分类是非常细且非常分散，在后续工作中对图书进行归类与聚类分析时就会由于其分散而划分不明显，因此，在查询分析器中进行数据处理，抽取分类号第1个字母为大类，第二个字母为小类，第三个字母为细类，这样可将图书分为三级，即大类、小类、细类。大类别与中国图书馆图书分类法中的22个基本大类将对应，小类别对应于每个大类下的下属位，细类则对应于小类的下属位。处理方式如下（利用SQL语句可将其处理成我们所需要的数据形式）：表4.5说明了其使用的函数及其处理后的数据结果。因为分类号小数点后的分类过于细微，本次研究忽略后面的数字，只取着三位数进行分析。

表 4.5 经过处理的图书信息

Table4.5 Processed books information

Use cqudata				
Select left (cl,1) dl,left (cl,2) xl, left (cl,3) xxl, from [cqudata].[dbo].[library_lenddata]				
go				
dl	xl	xxl	cl	title
C	C9	C92	C9200792	社会学大纲
F	F8	F83	F832003100	股市操练大全
F	F2	F25	F25200691	供应链管理
F	F7	F75	F7520066	国际工程总承包项目管理
T	TP	TP3	TP3162007129	Sun Solaris 9/10系统管理员认证指南
O	O1	O13	O13200175	高等数学试题解析
T	TG	TG3	TG3920071	成形工艺与模具设计
H	H3	H31	H313200622	最新四级词汇快突破4500词
H	H3	H31	H315200710	英汉名篇名译
H	H3	H31	H313200572	大学英语四级考试词汇必备

③借阅时间转换

学校的作息时间是具有规律性的，一般而言在寒假或者是暑假期间读者便没有可能访问图书馆，因此也就不会存在借阅记录，在正常的上学时间段，图书馆的借阅量每年、每个星期、每日均会有差异，因此通过对不同的年份、月份、星期及小时的分类，能够让时间特性更明确，这种时间上的划分也可以作为读者借阅行为的一种属性特征。

日期及时间的存储类型在不同的数据库中都有不同的表达方式，在本库中的图书馆管理系统中对于读者借阅时间的存储类型为 **datetime**，存储方式如：2010-04-03 20: 35: 15.162，系统中该种时间类型可以具体到微秒，为了便于后续工作的展开，因此将借阅时间的属性分成几个部份：借阅年份 (j_year)、借阅月份 (j_month)、借阅日期 (j_day)、借阅时间 (j_hour)、借阅星期 (j_week)，相应语句如下：

```
select datepart (year,借出时间) j_year, datepart (month,借出时间) j_month,
datepart (day,借出时间) j_day, datepart (weekday,借出时间)-1 j_weekday, datepart
(hour,借出时间) j_hour into cqudata.dbo.linshi from cqudata.dbo.dzjy)
```

处理结果如下图4.6所示

dl	xl	xod	cl	title	reader	mum	j_year	j_month	j_day	j_week	j_hour
C	C9	C92	C9200792	社会学大纲	谭圣芳	20062302018	2008	10	7	2	10
F	F8	F83	F832003100	股市操练大全	寇军	20070197004	2010	6	28	1	12
F	F2	F25	F25200691	供应链管理	廖国栋	20090703148	2010	6	17	4	9
F	F7	F75	F7520066	国际工程总承包项目管理	刘方强	20060301002C	2008	11	3	1	10
T	TP	TP3	TP3162007129	Sun Solaris 9/10系统管理员认证指南	黄河	20051402096	2008	6	11	3	16
O	O1	O13	O13200175	高等数学试题解析	韩健	20083890	2009	4	17	5	18
T	TG	TG3	TG3920071	成形工艺与模具设计	张阳鹏	20072002021	2008	7	4	5	16
H	H3	H31	H313200622	最新四级词汇快突破4500词	陈祖阳	20083622	2009	10	13	2	11
H	H3	H31	H315200710	英汉名篇名译	张新竹	20085557	2009	7	10	5	12
H	H3	H31	H313200572	大学英语四级考试词汇必备	汤?爆?	20090507	2009	11	6	5	9
B	B2	B22	B22007209	于丹《庄子》心得	姜洋	20081544	2009	3	2	1	21
F	F8	F83	F832007294	货币战争	王弄枫	20084609	2009	6	30	2	12
T	TU	TU2	TU202006137	AutoCAD土木建筑绘图应用教程	刘保求	20091602097	2009	9	22	2	11
T	TU	TU2	TU202007198	建筑快速表现技法	李程远	20065615	2009	10	20	2	16
T	TP	TP2	TP2420071	机器人学	汤毅	20081301005	2009	4	13	1	15

图 4.6 借阅时间转换

Fig4.6 The transformation of borrowing time

上图中，j_month字段中所显示的数值即为月份，如10就是10月份，对于j_day与j_week与之相同，在j_hour中所显示时间10即借阅时为是10点到11点之间。

4.2.3 数据集成

在进行数据挖掘前，读者信息表、借阅信息表、馆藏信息表、读者类型表、

院系信息表等为数据挖掘提供了最基础的数据，形成待挖掘数据集，这些数据除了进行预处理以外还需要对数据表进行统计，生成对数据挖掘有用的统计数据表。如图书被借阅次数、读者借阅次数等。以下为数据集成的步骤：

①根据数据挖掘模型的需要，从业务数据中选择数据存储至待挖掘数据集中。

②根据表间关系和各方面的信息，填充空值，删除无用数据信息及属性，形成挖掘所需的直接信息表。

③对数据表中需要统计的属性进行统计。如图书被借阅次数、读者借阅次数。

根据挖掘所需的内容，图书馆图书借阅情况只需创建一个表即可，其应该包含以下字段属性：图书所属大类、图书所属小类，图书题名、借阅次数。这可根据借阅信息表与馆藏信息而得出。其表中结构信息如下表4.6，4.7所示：

表 4.6 图书借阅次数集成表

dl	xl	title	number_title
O	O1	高等数学	3229
O	O1	线性代数	2699
T	TP	C语言程序设计	1739
O	O2	概率论与数理统计	1232
K	K8	物理学	911
B	B5	物理学	911
.....			
H	H3	新视野大学英语	346
F	F2	计量经济学	288

表 4.7 读者借阅次数集成表

rnum	reader	number_reader	rtype	rdepart	xydm
20084399	矫金龙	512	本科生	动力工程学院	10
20070202094	吴宝霞	409	硕士研究生	经济与工商管理学院	2
200230147	靳晓光	389	教师	土木工程学院	16
.....					
20073195	蔡彬	324	本科生	光电工程学院	8
20070602092	程金静	316	硕士研究生	数学与统计学院	6
20080701002	葛红玉	313	博士研究生	机械工程学院	7

续上表 4.7:

.....					
20070402010	李茂凤	293	硕士研究生	外国语学院	4
20073638	季探宇	288	本科生	材料科学与工程学院	9
.....					

在关联规则分析中，我们要借鉴食品商店及超市中数据信息的例子，通常称作购物篮事务（market basket transaction），即表中每一行对应一个事务，包含一个唯一的标识（TID）和给定顾客购买商品的集合。对于图书馆的借阅数据来讲，我们要将其处理集成，将每一个读者借阅的书籍放到一个项集中，且对于每本书来讲，如果某位读者对该类书籍有过借阅行为，取值为“1”，否则为“0”。其处理结果如图4.7所示。

mum	numb...	rtype	rdepart	books	F2	F3	F4	F5	F6	F7	F8	F9	FA	FH	FM
20043942	96	本科生	自动化学院	B82003143,B82003...	0	0	0	0	0	0	0	0	0	0	0
20043968	28	本科生	自动化学院	H319200335,I1620...	0	0	0	0	0	0	0	0	0	0	0
20043975	111	本科生	自动化学院	F23200349,I23520...	1	0	0	0	0	1	0	0	0	0	0
20044049	52	本科生	自动化学院	B82007258,B82007...	0	0	0	0	0	0	0	0	0	0	0
20044081	50	本科生	自动化学院	B0200440,B920056...	1	0	1	0	1	1	0	0	0	1	0
20044116	130	硕士...	自动化学院	H3192007299,TB6...	0	0	0	0	0	0	0	0	0	0	0
20044195	39	本科生	计算机学院	F272004323,TM93...	1	0	0	0	0	1	1	0	0	0	0
20044207	20	本科生	计算机学院	C92005225,D9202...	0	0	0	0	0	0	1	0	0	0	0
20044237	25	本科生	计算机学院	TP3122005100,TP...	0	0	0	0	0	1	0	0	0	0	0
20044273	8	本科生	计算机学院	TP311200184,TP3...	0	0	0	0	0	0	0	0	0	0	0
20044295	28	本科生	计算机学院	TP3112006322,TP...	0	0	0	0	0	0	0	0	0	0	0
20044300	6	本科生	计算机学院	TP3112007360,TP...	0	0	0	0	0	0	0	0	0	0	0
20044419	6	本科生	计算机学院	TP3112003164,TP...	0	0	0	0	0	0	0	0	0	0	0
20044600	68	本科生	建筑城规...	B22008180,B82005...	1	0	0	0	0	1	0	0	0	0	0
20044712	12	本科生	建筑城规...	TU120100756,TU120...	0	0	0	0	0	0	0	0	0	0	0

图 4.7 读者借阅事务数据

Fig4.7 Readers' borrowing affairs data

从上图中，可以进行简单的解释说明，对于读者号分别为20044081与20044116的两位读者来讲，从学生类别与借阅数量上来看，前者属于本科生，总借阅次数为50本，后者是一名研究生，借阅次数为130本，在其借阅的类型上来看，本科生偏向于类别属于F（经济类）类的书籍，因其在图书分类上的数值为1,而该研究生则对于类别属于F类的图书并不感兴趣，从books这一栏看，其感兴趣的书籍是关于H（语言文字）与T（工业技术）类的书籍。

通过对原始数据的清洗、转换与集成，我们得到了挖掘时所需的最终满足要

求的数据。并在总共的数据基础上将其分为若干个信息表。

4.3 算法的选择

本次挖掘实例中主要用到两种算法：聚类算法和关联算法。两种算法因在应用及数据处理格式上的不同而分为多种类型。因此需要通过比较分析找出一个最合适的算法对数据进行处理。

4.3.1 关联算法的比较

关联规则是数据挖掘领域一个重要的研究内容，所谓关联规则就是通过分析，找出给定项目组与事务记录集合中项目之间未知的依赖关系。在关联规则研究中，最著名的算法是Agrawal提出的Apriori算法，除此之外还有FP-Growth算法、AprioriTid算法等^[53-54]。

①Apriori算法

Apriori算法是个布尔、单维、单层关联规则，算法的核心思想是采用一种逐层方法来产生关联规则，其中每层对应于规则后件中的项数。初始，提取规则后件只含一个项的所有高置信度规则，然后，使用这些规则来产生新的候选规则。例如，如果 $\{ACD\} \rightarrow \{B\}$ 和 $\{ABD\} \rightarrow \{C\}$ 是两个高置信度的规则，则通过合并这两个规则的后件产生候选规则 $\{AD\} \rightarrow \{BC\}$ 。

②FP-Growth算法

FP-Growth树算法是一种输入数据的压缩表示，它通过逐个读取数据库中的事务，根据事务中各项集出现的次数来构造频繁模式FP_树，同时用模式树保留各项集的关联信息。然后由长度为1的频繁模式开始在构造树的同时递归地对树进行挖掘。

③AprioriTid算法

AprioriTid算法与Apriori算法相比，减少了对原始数据库的扫描次数，逐渐减少候选事务数据库代替原始数据库，随着候选项集的减少AprioriTid只要扫描比原始数据库小得多的数据库就可以。

对于FP-Growth算法和AprioriTid算法有过大量的理论研究，其在理论研究中，处理速度都高于Apriori算法，但在实际应用中还没有广泛用于大型数据挖掘软件工具当中，而Apriori算法到目前为止是应用当中最为成熟的一个，鉴于工具选择上的限制，我们本次研究工作采用Apriori算法进行。

4.3.2 聚类算法比较

聚类分析算法取决于数据的类型、聚类的目的和应用。主要分为以下几个类：划分方法、层次方法、基于密度的方法、基于网格的方法以及基于模型的方法等，对于每一类中均有各自典型代表算法。这里以划分方法中的K-Means算法，层次方

法中的BIRCH算法及基于密度的方法中的DBSCAN算法（Density-Based Spatial Clustering of Applications with Noise）进行比较说明^[55-57]。

K- K-Means算法

K-Means算法比较简单，其一开始以选择K个初始质心，其中K是用户指定参数，即所期望的簇的个数。每个点指派到最近的质心，而指派到一个质心的点集为一个簇，再根据指派到簇的点，更新每个簇的质心。重复指派和更新步骤，直到质心不发现变化。当K-Means算法结果簇是密集的，且簇与簇之间具有明显的区别时，它的效果就比较好。在面对大规模数据集，其具有相对可扩展性，并且具有较高的效率。

②BIRCH算法

BIRCH算法（平衡迭代削减聚类法）利用层次方法进行平衡迭代归约和聚类，采用多阶段聚类技术，对数据集进行一次性扫描先产生一个基本的聚类，在此基础上再进行多遍额外扫描，对第一次所产生的聚类进行改进，从而提升聚类质量。该算法的优点是对噪声不敏感，在数据量大时，可以进行线性伸缩。

③DBSCAN算法

DBSCAN算法（基于高密度连接区域的密度聚类法）其主要思想是：在每一个类中其半径邻域内必须至少包含一定数量的点，即邻域的密度必须超过一个定值。也即根据类的密度值来限制类的增长，将达到一定密度的区域划分为一个类。其优点是可在带有“噪声”的数据中发现任意形状的聚类。

基于上述分析，对于数据挖掘中聚类算法比较结果如表4.8所示：

表 4.8 数据挖掘中聚类算法比较

Table4.8 The comparison of the clustering algorithm

算法类别	类型	可伸缩	数据类型	聚类形状	噪声 敏感性	时间复杂度	处理高维数 据能力
K-Means	优化	较高	数值	任意	敏感	O（nkt）	较高
BIRCH	优化	较高	数值	凸状/球形	不敏感	O（n）	较低
DBSCAN	关系	一般	数值	球形	一般	O（n2）	较低

通过上述比较，BIRCH算法对于簇大小的限定主要采用阈值，类的边界是用半径或者直径来控制，因此，对于不是球形的簇，BIRCH算法就会受限；DBSCAN算法对于处理噪声比较多的数据空间具有可靠性，且仅能发现圆形或球状的聚类，而图书馆中数据簇的形状是不固定的，因此，这两种方法均不适合。K-Means算法对于最终数据簇的结果并无限制，且在处理大数据集时，具有相对可伸缩性和高

效性。其对处理噪声数据的敏感性虽不高，但可以在数据预处理中进行弥补。因此在聚类方面采用K-Means算法建立挖掘模型，对读者进行细分。

4.4 基于聚类对读者细分

从事务数据表中可以得知，每条借阅记录中包含着诸如以下几个信息：读者号（rnum），读者借阅数量（number_reader），读者类型（rtype），读者所在院系（rdepart）及读者对每本书的借阅情况（books）。因此对读者的细分可以从两个方面进行聚类挖掘：一是根据全部读者的使用情况进行聚类挖掘划分读者群；二是从读者的类型、兴趣及借阅偏好上进行聚类挖掘。最后根据得到的聚类情况提取每个聚类的借阅意愿，从而构建读者借阅模式，最后从各类出发，提取分别属于每个类的具体读者，再依据关联规则找出各借阅项目间的规则，推荐给最适合的读者。

4.4.1 借阅情况聚类挖掘

在图书馆的实际工作中，我们发现，对于读者而言，有些读者几乎每周都要借书还书，对图书馆的访问较高，而对于其他一些读者而言，一年也难得来上几次，其对图书的借阅需求就少之又少。因此可以根据这一特点，使用聚类算法将他们划分为不同的组。组内之间，读者的借阅图书分类构成比较相似，而组与组之间读者的借阅图书分类构成比较相异。因为是对借阅数量上的一种反应，因此将会观察到读者借阅频率的高低。下面根据所处理的数据表，应用K-Means聚类算法进行实际挖掘。

本文根据对处理数据的反复挖掘，以及经验，将聚类数K定于3-7之间，分别求出读者细分对应的聚类情况。结果发现：

K的取值过小，簇的涵盖范围就越大，某一簇内成员占去总数的70%以上，对于这样的划分，不能发现有效模式。

K的取值过大，统计数据可信度不高，簇内整体表现不精确，数据类型过于分散，描述模型不可用。且对于以后的关联规则分析来讲操作性不高。

通过对K值的不断调整，最终将K值确定为5,即将读者细分为5个大类。如图4.8所示：




图 4.8 读者细分

Fig4.8 Readers subdivision

在上图4.8中反应了读者根据其借阅情况而被划分到不同的类。在本次挖掘中，挖掘对象总共有23,743位用户。从上图划分的情况可以看出，在这5个类中，其中聚类-1中用户最多，总共为13,535个用户，占全体读者的57%，而对于这一类的读者来讲，其借阅量均值为13本图书，借阅量较少。借阅量最多的读者类为聚类-2，其每位读者借阅均值为240本。该类用户数只有101人，仅占总人数的0.001%。但由于该类的方差太大（50.6），即该类用户在借阅量上凝聚性不高（在统计学上即为集中趋势），借阅数量比较分散。对于其他三个聚类来讲（聚类-4、聚类-3、聚类-5），总体借阅量跨度在50-150本图书之间。且每个类别分以借阅量50为一次划分。

因此根据以上结果可得知，总体上，绝大多数读者对图书馆的利用率较低，四年来，有将近一半的读者仅借了十多本书。另一半读者的借阅量又可划分为三个层次，第一类则为聚类-4，该类用户借阅量在50本左右，且占总人数的30%。聚类-3借阅量为90本图书，仅占总人数的12%。聚类5借阅量为143本左右，占总人数的3%。

本次数据范围总共包含了四年的借阅数据，数据时间跨度为2007-2010年，刚好是本科生的一个完整周期，根据此数据，我们可以跟踪2007级新生到毕业时他们整个学业期间的借阅行为动态。经过对其每一年中借阅类别的变化趋势的分析，可以得知，新生在刚入学时对图书馆的利用率比较低，随着慢慢适应到大学中来，其借阅量有明显的增加。其借阅情况如图4.9所示：




图 4.9 2007 级读者借阅趋势图

Fig4.9 The diagram of Lending trend

从上图可以看出，2007级的读者在这四年来借阅图书的类别上并没有发生明显的改变，对于每种类型的书籍来讲，均从2007年开始到2008、2009年有大幅度增长，2010年又明显回落。但从图中还可以得知，新生在刚开学时期，对I类图书比较关注，借阅量比较大，这是由于读者都比较爱好文学小说类的书籍，随着专业讲的开课，读者又偏好于F（经济），O（数理科学和化学），T（工业技术）类的图书，同时也开始关注人文艺术与哲学宗教类的图书，可能是因为随着年龄的增长，对人生，生活有了新的见解，随着学习的深入并对当代社会教育及科学有了看法，这就导致读者在学习的过程中也关注整个社会的教育体制问题，因此，读者对于G类图书借阅量也有明显增加。

4.4.2 读者偏好、类型上的聚类挖掘

通过将读者的类型，所属学院及其借阅偏好等属性作为聚类的依据，可以得知，哪些用户在总体上对哪类图书感兴趣，并依据他们的相似之处将读者划分为不同的类别。这样一来，可以根据每个类的总体特征与新来读者的偏好、类型进行匹配，并向其有针对性的提供个性化信息服务。

首先，提取所需的信息，各字段信息情况如图4.7所示，只需读者号、读者类别、读者所在院系及读者借阅图书的类别信息。每位读者对每本书的借阅情况先暂不做考虑。

其次，对数据进行聚类，在聚类的过程中也需要不断调整与优化，最终，可得到最优聚类数为7个大类。为了便于图形的直观性解读，本次聚类图形经过改善布局后得到如下图4.10所示：




图 4.10 读者偏好、类型的聚类

Fig4.10 The Clustering of reader's preferences and type

从上图4.10中，各类之间通过线段相连（该图显示的链接强度为50%，即中度链接），而线的深浅则表示类别之间的联系程度。我们可以看出，整体图形划分为两个大的区域，分类3、分类4、分类5、分类6之间联系比较密切，可以看作一个局部整体，我们称其为A区域。分类1、分类2、分类7之间的关系也比较密切，可以看作是另一个局部整体，称其为B区域。A、B两个区域通过分类6与分类7相联系。

经过对各分类信息的查看，得知，A区域以硕士研究生和博士研究生为主，且借阅书籍类型以文为主；B区域则以本科生为主，借阅书籍类型以理工科为主。以上各区域学生的主要类别并不意味着读者均是某一类别学生，仅表明某类别学生在该类中居多而已。

最后，根据聚类的结果，分析出每个类中的主要属性特征，为了方便解读分类的具体情况，我们可以根据图4.11分类剖面图进行读者借阅模式的提取。




图 4.11 分类剖面图

Fig4.11 classification section

从总体上来看，读者类别分属本科生、硕士研究生、博士研究生均对工业技术（即T类）的图书感兴趣，也即是这三个类别读者的共同爱好之处。

以下对每个聚类类别借阅模式进行简单说明，由于第二章2.5小节中已经给出了中国图书馆图书分类所对应的各类目号，因此对于每个聚类中读者的借阅倾向用中国图书馆图书分类法中的大类类号代替说明。

学生类别为本科生、院系属于土木工程学院、电气工程学院、贸易与行政学院、数学与统计学院倾向于借阅T、I、H、K 类图书的读者被划分为一类即：类1。

学生类别为本科生，院系属于机械工程学院、艺术学院、计算机学院、美视电影学院、材料科学与工程学院、建筑城规学院倾向于借阅T、O、Q、J、B类图书的读者被划分为一类即：类2。

学生类别为研究生，院系属于建筑城规学院、体育学院、贸易与行政学院，资源及环境科学学院、经济与工商管理学院、土木工程学院倾向于借阅B、C、P类图书的读者被划分为一类即：类3。

学生类别为本科生（16%）、研究生（64%）、博士生（20%），动力工程学院、电气工程、法学院、软件学院倾向于借阅T、V、U、N、D类图书的读者被划分为一类即：类4。

学生类别为研究生、院系属于通信工程学院、生物工程学院、化学化工学院、机械工程学院倾向于借阅T、K、G、N、F、R类图书的读者被划分为一类即：类5。

学生类别为本科生(54%)、研究生(46%)，光电工程学院、城市建设与环境工

程学院倾向于借阅A、B、C、D、E、H、I、K、N、O、P、Q、R、S类图书的读者被划分为一类即：类6。

学生类别为本科生、经济与工商管理学院、建设管理与房地产学院、动力工程学院、法学院倾向于借阅Z、J、K、I、O、H类图书的读者被划分为一类即：类7。

从以上7个大类中，我们可以看出，类6中光电工程学院、城市建设与环境工程学院的本科生与研究生的兴趣爱好比较广泛，每种书籍均有涉及。为便于直观性的了解读者的借阅模式，以下表4.9表示每个类中的主要特性。

表 4.9 各类属性特征

Table4.9 The characteristics of each attribute

分类	属性特征 学生类别 (%)	主要院系	主要书目类
类1	本科	土木工程学院、电气工程学院 贸易与行政学院、数学与统计学院	语言文字、文学、历史地理、工业技术
类2	本科	机械工程学院、艺术学院、计算机学院 美视电影学院、材料科学与工程学院 建筑城规学院	数理科学和化学、生物科学、哲学、宗教艺术、工业技术
类3	硕 士 90% 博 士 10%	建筑城规学院、体育学院、贸易与行政学院 资源及环境科学学院、经济与工商管理学院、土木工程学	天文学、地球科学、哲学与宗教、社会科学理论与方法论、
类4	本 科 16% 硕 士 64% 博 士 20%	动力工程学院、电气工程 法学院、软件学院	政治、法律、交通运输、航空、航天、自然科学、工业技术
类5	硕士	通信工程学院、生物工程学院 化学化工学院、机械工程学院	医药卫生、文化、科学、教育、体育、经济、历史地理、自然科学
类6	本 科 54% 硕 士 46%	光电工程学院、城市建设与环境工程学院	每个类别均有涉及
类7	本科	经济与工商管理学院、动力工程学院 建设管理与房地产学院、法学院	综合性图书、历史、地理、数理科学和化学、文学、艺术

根据上面所得到的7个聚类结果，即读者按不同的借阅行为被分为不同的类别当中，且同一类别当中的读者借阅行为相似而不同类别当中的读者借阅行为不相似，根据这个结果即得到读者划分的情况也就是我们所说的读者细分。每个类也表示为一个读者借阅模型。

有了读者细分的类，可以提取每个类中具体借阅数据，根据这些被细分后的借阅记录进行关联挖掘，找出规则，形成知识库，最终向读者提供个性化服务——个性化推荐。

4.5 关联规则挖掘

传统的规则推荐都是将全部信息作为产生规则的数据源或是主观性的根据读者的自身属性特征（读者所在院系，性别等因素）对读者进行分类，以每个类中的借阅信息作为产生规则的数据源，然后对每位读者实行规则推荐。从关联规则算法理论上看规则的产生是依据支持度和置信度，而支持度和置信度的确定是根据所有记录而得出，这样对于规则中最小支持度和最小置信度的确定都是人为设置，定的太高，规则数目太小不能反应事实，定的低又将一些个别或偶然列入其中，使得弯曲面更大。为了减少这种弯曲事实的产生，我们在对读者推荐图书时，先对其进行归类划分，确定其归类后再依据其所属类中的规则模型进行图书推荐。

4.5.1 基于图书的关联分析

图书的关联分析实质上主要是对读者借阅过的图书进行关联分析。采用的是Apriori算法实现，最终产生的规则是形如 $x \rightarrow y$ 的蕴涵表达式，其中 x 和 y 这两个项集并不相交，即 $x \cap y = \emptyset$ ，由此所产生规则的强度可以用支持度和置信度量。给定数据集的频繁程度可以用支持度来确定，而置信度用来确定 y 在包含 x 的事务中出现的频繁程度。支持度(S)和置信度(C)这两种度量的形式定义如下式（4.1），（4.2）^[58]：

$$S(x \rightarrow y) = \frac{\sigma(x \cup y)}{n} \quad (4.1)$$

$$C(x \rightarrow y) = \frac{\sigma(x \cup y)}{x} \quad (4.2)$$

关联规则的挖掘问题就是生成所有满足指定的最小支持度和最小置信度的关联规则。满足最小支持度和最小置信度的关联规则称为强关联规则。

本次关联规则挖掘从两方面进行：一方面对全部读者借阅图书进行关联规则分析；另一方面是通过对聚类所得的读者借阅图书进行关联规则分析。

4.5.2 全部读者所借图书关联挖掘

在关联挖掘之前，首先计算每本图书被借阅的次数，根据其借阅次数的分布

情况，合理的选择关联挖掘所需的数据。图书借阅频次分布情况如图4.12所示：




图 4.12 图书借阅次数分布

Fig4.12 The distribution of books lending frequency

据图4.12可知，本次挖掘数据中，总共有135,271本图书被读者借阅，对于那些借阅频次在1-5次之间的图书仅占借阅总量的14%。由关联规则产生的计算方法上看，借阅次数较小，则其出现的频率就越低，由此产生的规则质量不高，因此，本次挖掘将剔除那些借阅频率较小的记录。

设置关联规则的最小支持度S的取值，在最终确定S的取值之前，要进行多次调试，因为最小支持度S取值过小，导致最终得出的关联规则结果过多，不能发现有效模式，关联规则质量不高；S取值过大，一方面导致某些隐含的关联规则未被挖掘出来，也可能导致规则失去意义，另一方面导致关联规则没有运算结果，失去可操作性。

本文通过不断调试，最终确定S取值为0.5，对于置信度的确定本文设置为0.4。即如果图书A、B的支持度与置信度分别大于0.5与0.4,则表明读者在借阅A图书的同时，有一定的可能去借阅B图书。根据此规则，就可以向借阅了A图书的读者推荐B图书。在以支持度为0.5，置信度为0.4的条件下挖掘的结果如下图4.13所示：

▼	概率	重要性	规则
0.909			钢筋混凝土结构 = 现有 -> 钢结构 = 现有
0.909			荷包里的单人床 = 现有, 刻骨的爱人 = 现有 -> 卖海豚的女孩 = 现有
0.909			人力资源管理案例·习题集 = 现有 -> 人力资源管理 = 现有
0.909			斯泰尔斯庄园奇案 = 现有, 空谷幽魂 = 现有 -> 人性记录 = 现有
0.909			无机化学学习指导 = 现有, 物理化学 = 现有 -> 有机化学 = 现有
0.882			建设工程技术与计量 = 现有, 工程造价管理基础理论与相关法规 = 现有 -> 工程造价计价与控制 = 现有
0.867			建设工程经济 = 现有, 建设工程法规及相关知识 = 现有 -> 建设工程项目管理 = 现有
0.867			中华人民共和国行业标准 = 现有, 中华人民共和国国家标准 建筑抗震设计规范 GB50011-2001 = 现有 -> 中华人民共和国
0.857			飞狐外传 = 现有, 倚天屠龙记 = 现有 -> 笑傲江湖 = 现有
0.857			世界小住宅 3 = 现有, 世界小住宅 1 = 现有 -> 世界小住宅 2 = 现有
0.857			现行建筑结构规范大全 = 现有 -> 中华人民共和国国家标准 = 现有
0.846			靓女芳心 = 现有, 今生注定 = 现有 -> 席娟2005新作展 = 现有
0.846			微积分习题集 = 现有, 线性代数 = 现有 -> 微积分 = 现有
0.846			习题分析与解答 = 现有, 机械制图习题集 = 现有 -> 物理学 = 现有
0.833			安东尼·高迪 = 现有, 勒柯·布西耶 = 现有, F.L. 赖特 = 现有 -> 弗兰克·盖里 = 现有
0.833			飞狐外传 = 现有, 鹿鼎记 = 现有 -> 笑傲江湖 = 现有
0.833			飞狐外传 = 现有, 笑傲江湖 = 现有, 天龙八部 = 现有 -> 倚天屠龙记 = 现有
0.833			飞狐外传 = 现有, 倚天屠龙记 = 现有, 笑傲江湖 = 现有 -> 天龙八部 = 现有
0.833			弗兰克·劳埃德·赖特 = 现有, 建筑画 = 现有 -> 勒·柯布西耶 = 现有

图 4.13 关联规则挖掘结果

Fig4.13 The results of Association rules mining

从图4.13中可以看出, 读者借阅了《钢筋混凝土结构》(TU37200425)后, 有90%的可能性继续借阅《钢结构》(TU39200112)这本书, 这一规则的前件只有一个项集, 我们称其为1项集, 同时, 读者借阅了《建设工程技术与计量》(TU72200664)和《工程造价管理基础理论与相关法规》(TU72200797), 后有88%的可能性继续借阅《工程造价计价与控制》(TU722008157), 对这样一种规则即叫做2项集。在本次挖掘中, 我们设置的最大项集数 (Maximum_Itemset_Count) 为0, 即算法将生成所有可能的项集, 其最大项数是根据计算机自身硬件及系统内在所决定。

4.5.3 已聚类群中的关联挖掘

上小节中关联规则挖掘的结果来自全部数据, 由于是4年的借阅数据, 因此其基数较大, 生成的规则过多, 占总共的80%以上, 其虽在置信度上较大, 不排除规则的质量低, 因为数据量越大, 其读者四年来重复数据也就越多, 这样的话就增加了某一借阅事例的数量, 从而就增大了其支持度。因此基于此原因, 我们应该从三个方面考虑数据挖掘的范围: 时间、类别、借阅量。

因此一次关联规则应以一年作为一次挖掘数据源跨度, 并提取每个聚类模式里的借阅记录, 最后确定每个聚类群中的借阅量值。

在此, 本文以聚类2群体中所有用户借阅记录为挖掘源, 借阅年份为2009年, 读者借阅量大于等于50, 小于等于150。取此值是因为, 该值分布于读者借阅均值左右, 取值过小, 难以形成良好的规则。最终形成的依赖关系网络与关联规则结果如图4.14、图4.15所示:

从图4.15中可以看出，读者借阅了《构成设计》（J06200562）后，有75%的可能会继续借阅《立体构成》（J5020006）这本书，同时读者借阅了《线性代数与空间解析几何》（O15200313）和《大学物理》（O4200716）后，有85.7%的可能性会借阅《大学物理学》（TB1320032）这本书，还有同时借阅了《良辰讵可待》（I2472008372）和《执手千年》（I2472007468）的读者会有83%的可能会继续借阅《凤舞战歌》（I2472008443）这本书。

通过对全部数据进行聚类后，从中提取适当的借阅记录进行关联规则挖掘，不仅在挖掘质量上有所提高，且减少了算法运行时间。并使关联规则数从全部数据应用中所得到的2000多个减少到现在的329个，剔除了无效规则。将所得的规则导入数据库中形成知识库，以供读者个性化服务使用。

4.5.4 关联规则的推荐

以上，首先完成了对读者细分即读者借阅模式，其次根据各分类的数据进行关联挖掘得到规则库。在完成了这两步后，最后就是将读者借阅模型与关联挖掘出的结果用于读者的个性化服务——个性化推荐。这一步骤比较简单，读者在登录系统之后，系统自动将读者的个人属性特征（读者类别、读者所在学院）及读者的借阅偏好信息与之前所生成的读者借阅模式进行匹配，根据匹配的结果，从读者归属类别中生成的关联规则向读者提供个性化推荐。

5 结论与展望

5.1 结论

随着数字图书馆信息资源的飞速增长，在数字图书馆中开展个性化服务已经成为一种趋势，它的最大优点就是能够根据读者的自身特性、专业背景及其目的提供满足个性化需求的信息资源服务。为了能够实现这样的功能，数字图书馆就应该利用当下成熟的数据挖掘技术，对数字图书馆中存储的大量借阅信息记录进行挖掘分析，这一工作分两步展开，首先依据读者的借阅记录将其进行分类，使得每一类具有相同的数据特征后，建立用户信息模型；其次提取各类中的数据信息，运用关联规则挖掘找出关联模式。根据以上两个步骤所得的结果，向读者提供个性化服务。这不仅有助于了解读者群体特点、提高读者的到馆率、优化馆藏结构，为管理决策提供科学的数据基础，而且对深化数字图书馆的服务层面有非常重要的意义。论文完成的主要工作有：

①总结和概括了国内外数字图书馆个性化服务的研究现状，并将国内与国外的研究现状进行了比较。结果发现国内数字图书馆个性化服务功能比较单一，与国外相比，研究起步比较晚，国内研究还处于理论层面，对于个性化服务的实践应用刚刚起步。

②论述了数据挖掘的概念，任务、过程，介绍了数据挖掘的主要方法，同时对数字图书馆用到个性化服务技术进行了概括，介绍了个性化服务的主要方式。

③基于数据挖掘技术，设计出了一个数字图书馆个性化服务系统整体模型，对模型的功能进行简单描述，详细介绍了个性化服务系统中在线推荐及离线挖掘两个模块及其工作流程。

④从读者借阅量及读者偏好、类型两方面对数字图书馆中存储的读者借阅记录进行聚类挖掘。根据借阅数量的聚类挖掘分析，可以观察到读者借阅频率的高低，从中发现读者借阅需求的分布情况，为提高关联规则分析提供数据基础。根据读者偏好、类型的聚类分析，将读者分成了7个大类，找出每个类中的数据特征即借阅模式。

⑤运用关联规则方法，根据聚类的结果对读者借阅信息进行规则挖掘，找出规则模式，为读者提供个性化信息推荐服务。

5.2 展望

本文对数字图书馆中开展个性化服务进行了初步研究，在理论与实验方面取得了一些成果，但是还存在着许多不足。

①引入兴趣度指标

传统的关联规则挖掘算法采用的是支持度—置信度模型，经过对支持度与置信度的设置，过滤掉那些小于用户设定的最小支持度与置信度的规则，对于那些大于用户设定的最小支持度与置信度的规则将其输出，形成最终的规则模型，根据这些规则向读者进行图书推荐。然而，这种方法产生的规则并不一定是用户感兴趣的，如果引入兴趣度指标，就可以将读者的兴趣添加到挖掘算法中，从语义层面上生成规则，这样就可以排除无关规则，同时随着时间的推移，用户兴趣度模型通过自适应调整用户兴趣特征词的权重和用户的兴趣主题变动来实现用户兴趣的转移。由此，可进一步正确挖掘读者感兴趣的规则，实现更准确的个性化推荐。

②基于评价的协同过滤

与传统关联规则推荐不同，协同过滤通过分析用户兴趣，在用户群中找到指定用户的相似（兴趣）用户，综合这些相似用户对某一信息的评价（打分），形成系统对该指定用户对此信息的喜好程度预测。通过预测的结果向用户进行推荐。因此数字图书馆书目信息中，应该实行打分评价机制，让每位读者浏览图书的同时，并给该书进行打分评价，基于此可以利用基于评价的协同过滤技术进行关联规则挖掘，开展个性化服务。

③数字图书馆的应用

本次数据挖掘的数据对象仅利用了数据库中存储的读者借阅信息记录，而每个读者在数字图书馆上进行图书浏览时都会生成浏览日志（浏览行为），如果再进一步对读者浏览日志（浏览行为）进行关联规则挖掘，可以得到更丰富的读者兴趣，扩展数据挖掘技术在数字图书馆中的应用范围。

致 谢

在研究生期间，很荣幸能够成为彭晓东教授的一名学生。我首先要感谢恩师的精心指导和悉心关怀，彭老师以其渊博的知识，深厚的理论功底，丰富的经验，严谨的治学态度，使我能够顺利完成论文。在三年的研究生学习阶段，彭老师在学业和生活上给了我很多指导、关心和照顾，让我不仅学习到了扎实、宽广的专业知识，提高了学术研究水平，还深刻的领悟到了许多为人处世的道理。我谨借此论文完成之际，向导师表示深深的敬佩和衷心的感谢。

同时在这里我还要感谢魏群义老师，他在我的论文的选题、资料收集以及撰写修改的各个过程也倾注了大量心血。在此向魏老师致以最衷心的感谢。

在此，还要感谢我的同门及教情班的每一位同学。尤其是匡昌华、袁玉琳等同学。他们在日常的学习和生活中给了我很大的帮助。在论文课题的研究过程中，共同的讨论为我论文的开展和思路的开阔起到很好的帮助作用。

再次衷心感谢所有关心和支持我的老师、同学和朋友们！

最后感谢各位评委老师在百忙之中抽出宝贵时间认真审阅本文。

王 哲

二〇一二年四月于重庆

参考文献

- [1] 房敏. 高校数字图书馆个性化服务综述[J]. 图书馆论坛, 2010, 33: 219-218.
- [2] 陈京民. 数据仓库与数据挖掘技术[M]. 北京: 电子工业出版社, 2004.
- [3] 刘晓东. 数据挖掘在图书馆工作中的应用[J]. 情报技术, 2005. 8: 16-19.
- [4] L. FernMndez, J. A. SMnehez. Model: Personal spaces in digital library universe. In ACMDL, 2003: 222-233.
- [5] 徐杰飞. 数字图书馆个性化服务研究综述[J]. 情报探索, 2010, 153(7): 116-118.
- [6] 焦玉英, 袁静. 开放环境下数字图书馆个性化集成服务研究[M], 2009年信息化与信息资源管理学术研讨回论文集. 数字化信息服务研究. 武汉: 武汉大学出版社, 2009: 8-17.
- [7] MyLibrary@NCstate [EB/OL]. <http://www.lib.ncsu.edu/mylibrary/Alerts.html>, 2011.07.10.
- [8] MyGateway [EB/OL]. <http://www.lib.washington.edu/resource/help/MyGateway.html>.
- [9] MyUCLA [EB/OL]. <http://my.ucla.edu/>
- [10] Tennant, Roy. Digital Libraries. Library Journal, July 1999: 36-38.
- [11] MyLibrary@Cornell [EB/OL]. <http://www.library.cornell.edu/services/mylibrary.html>, 2011-07-10.
- [12] 徐艳. 图书馆个性化服务研究综述[J]. 吉林广播电视大学学报, 2011, 8: 25-26.
- [13] 王翠萍. 国内外图书馆Mylibrary个性化服务系统比较研究[J]. 情报资料工作, 2004, (3): 67-70.
- [14] <http://159.226.100.135/mylibMry/>.
- [15] 浙江大学图书馆的MyLibrary@ZJU [EB/OL]. <http://210.32.137.206/mylib/mylib/index.asp>, 2011-07-10.
- [16] 华中科技大学MyLibrary@HUS [EB/OL]. <http://202.114.9.59/mylib/default.aspx>, 2011-07-10.
- [17] 中国人民大学图书馆“个性化信息服务”[EB/OL]. <http://www.lib.ruc.edu.cn/yhfw/index.htm>, 2011.07.10.
- [18] 武森, 高学东. 数据仓库与数据挖掘[M]. [德]M. 巴斯蒂安著. 冶金工业出版社, 2003. 9
- [19] JiaweiHan, MichelineKamber著. 范明. 孟小峰等译. 数据挖掘概念与技术[M]. 机械工业出版社, 2001.
- [20] 邵峰晶, 于忠清. 数据挖掘原理与算法[M]. 北京: 中国水利水电出版社, 2003: 91-115.
- [21] 王珊. 数据挖掘技术与联机分析处理[M]. 北京: 科学出版社, 1998: 102-114.
- [22] 熊拥军, 陈春颖. 基于关联挖掘技术的数字图书馆个性化推送服务[J]. 图书情报工作, 2010, 54(1): 125-129.

- [23] M. Elena. A personalized collaborative digital library environment. In 5th International Conference on Asian Digital libraries, 2002: 262-274.
- [24] Usan Dumais, Hao Chen. Hierarchical classification of web content. Proceedings of the 23rd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, New York, ACM Press, 2004: 256-263.
- [25] J. B. Schafer, J. A. Konstan, J. Reidl. E-Commerce Recommendation Applications, Data Mining and knowledge Discover Kluwer Academic, 2001: 115—153.
- [26] J. T. Tou, R. C. Gonzalez. Pattern Recognition Principles, Addison-Wesley, Reading, 1974.
- [27] K. Fukunaga. Introduction to Statistical Pattern Recognition, Book, Academic Press, New York, 1990.
- [28] U Maulik, SB and YoPadhyay. Genetic algorithm a self-clustering technique, Pattern Recognition, 2000 Vol. 33, No: 1455-1465.
- [29] 耿悦敏. 基于BP神经网络的预测模型[J]. 广东交通职业技术学院学报, 2007(4): 65-67.
- [30] Denning D E. An Intrusion Detection Model[J]. IEEE Trans on Soft Engineering, 1987, 13(2): 222-232.
- [31] 张文华. 基于读者行为特征的数据挖掘实例[J]. 图书馆杂志, 2009, 28(12): 55-58.
- [32] 罗宇红. 数字图书馆个性化信息服务实践研究[J]. 图书馆论坛, 2010, 30(4): 75-77.
- [33] 贾宏. 数字图书馆个性化服务技术述略[J]. 现代情报, 2006(3): 71—74.
- [34] WebWatcher Project. <http://www-2.cs.cmu.edu/afs/cs/project/theo-6/web-agent/www/project-home.html>.
- [35] M. Balabanovic, Y. Shoham. Learning information retrieval agents: Experiments with automated web browsing. <http://citeseer.ist.psu.edu/balabanovic95learning.html>.
- [36] Henry Lieberman. Letizia: an agent that assists web browsing. <http://lieber.www.media.mit.edu/people/lieber/Lieberary/Letizia/Letizia-AAAI/Letizia.html>.
- [37] 胡昌平, 李枫林. 杨成明. 网络信息服务的监督[J]. 中国图书馆学报, 2001(2): 20-24.
- [38] Underwood, GM. et al. User-centered Push for Timely Information Delivery. Computer Networks and ISDN Systems. 1998(30).
- [39] 潘秀琴. 国内外图书馆自动化系统比较分析[J]. 现代情报, 2007, 7(7): 126-130.
- [40] 中国图书馆图书分类法编辑委员会. 中国图书资料分类法[M]. 北京: 科学技术文献出版社, 2000.
- [41] 张鲁, 谭月辉, 苏春萍等. 数据挖掘技术在读者借阅行为分析中的应用[J]. 情报技术, 2005, 6: 36-40.
- [42] Haubl G, Trifts V. Consumer Decision Making in Online Shopping Environments: The Effects of Interactive Decision Aids Marketing Science, 2000.

- [43] Tsuex-Ho Hsu. An Application of Fuzzy Clustering in GroupPositioningAnalysis. Proc. Natl. Sci Counc. ROC(C), 2000, 1(10): 157-167.
- [44] Jean-Paul Ruiz, Jean Charles, C hebat, Pierre Hansen. Another trip to the mall: aSegmentation study of customers based on their activities. Journal of Retailingand Consumer Services, 2004, 11, 333-350.
- [45] H. WShin, S. Y. Sohn. Segmentation of stock trading customers according to Potential value. Expert Systems with Applications, 2004, 27, 27-33.
- [46] 安德智, 刘光明, 章恒. 基于协同过滤的图书推荐模型[J]. 图书情报工作, 2011, 55(1): 35-38.
- [47] 李忠俊, 周启海, 帅青红. 一种基于内容和协同过滤同构化整合的推荐系统模型[J]. 计算机科学, 2009, 36(12): 142-145.
- [48] 李冠宇. 基于混合算法的推荐系统的研究与实现[D]. 上海: 同济大学软件学院, 2008: 17-31.
- [49] 戚敏. 高校图书馆借阅数据关联规则挖掘研究[J]. 广西工学院学报, 2007(4): 77-90.
- [50] [http://lib.cqu.edu.cn/open/lib/DetailIntro.htm; jsessionid = D69E9158AC5ED871686C946ABEDB6F1B ?libIntroId=1.](http://lib.cqu.edu.cn/open/lib/DetailIntro.htm?jsessionid=D69E9158AC5ED871686C946ABEDB6F1B?libIntroId=1)
- [51] 陈文文. 图书馆使用者行为模式的数据挖掘研究[D]. 重庆: 西南大学, 2007: 13-27.
- [52] 胡佳. 几种典型关联规则算法的分析与比较[J]. 现代计算机, 2011, 08: 15-17.
- [53] 李宏运. 关联规则挖掘在图书馆管理中的应用[D]. 上海: 华东师范大学, 2009: 26-29.
- [54] 冯志新, 钟诚. 基于FP-tree的最大频繁模式挖掘算法[J]. 计算机工程, 2004, 30(11): 123-124.
- [55] R. Ng, J. Han. Efficient and effective clustering method for spatial data mining. In: Proc of the Int Conf on Very Large Data Bases. San Francisco, 1994, 14: 4-155.
- [56] T. Zhang, R. Ramakrishnan, and M. Livny. BIRCH: An efficient data clustering method for very large databases. ACM SIGMOD Record, 1996, 125(2): 103-114.
- [57] M. Ester, H. P. Kriegel, J. Sander, X. Xu. A density-based algorithm for discovering clusters in largespatial databases. In: Proc of the 2th Int'l Conf on Knowledge Discovery and Data Mining. Portland, 1996: 226-231.
- [58] 庄经纬. 基于社会网络分析方法和数据挖掘方法的网络论坛定量分析[D]. 重庆: 重庆大学, 2010:14-16.

附 录

作者在攻读学位期间发表的论文目录:

- [1] 彭晓东, 王哲. SSCI收录的图书馆学情报学期刊研究——基于JCR网络版(2009)的分析.